

LATVIJAS UNIVERSITĀTE
EKSAKTO ZINĀTŅU UN TEHNOLOĢIJU FAKULTĀTE

**TRENAŽIERU ZĀLES VINGROŠANAS NOTEIKŠANA
TREIŅAM ADAPTĪVAI MŪZIKAI**

BAKALaura DARBS

Autors: **Markuss Birznieks**
Studenta apliecības Nr.: mb20075
Darba vadītājs: Dr. comp. sc. Leo Seļāvo

RĪGA 2026

ANOTĀCIJA

Darbā tiek pētīta vingrošanas un atpūtas periodu noteikšana trenažieru zāles treniņā, izmantojot viedpulksteņa inerces sensoru datus. Šāda noteikšana tiek aplūkota kā vadības signāls treniņam adaptīvai mūzikai, kurai nepieciešams savlaicīgi un stabili noteikt vingrinājuma izpildes un atpūtas periodus. Darba ietvaros tika izveidots konvolūciju neironu tīkla (CNN) modelis binārai vingrošanas noteikšanai, apmācīts uz publiskajām trenažieru zāles aktivitāšu datu kopām un izvietots darbībai reāllaikā uz viedpulksteņa. Praktiskam eksperimentam tika izstrādātas Android lietotnes un ievāktas 10 treniņu sesijas ar 10 dalībniekiem. Rezultāti parāda, ka modeļa pielāgošana ar ievāktajiem datiem būtiski uzlabo noteikšanu, bet pēcapstrāde samazina signāla fragmentāciju un kļūdainas aktivizācijas, palielinot aizkavi.

Atslēgas vārdi: cilvēku aktivitāšu atpazīšana, adaptīvā mūzika, IMU, viedpulkstenis, CNN, HAR

ABSTRACT

GYM EXERCISE DETECTION FOR ADAPTIVE WORKOUT MUSIC

This thesis investigates the detection of exercise and rest periods during gym workouts using inertial sensor data from a smartwatch. This detection is considered as a control signal for workout adaptive music, which requires timely and stable recognition of exercise and rest periods. As part of the work, a convolutional neural network (CNN) model for binary exercise detection was developed, trained on public gym activity datasets, and deployed for real-time execution on a smartwatch. Android applications were developed for the practical experiment, and 10 workout sessions with 10 participants were collected. The results show that fine-tuning the model with the collected data substantially improves detection performance, while post-processing reduces signal fragmentation and false activations at the cost of increased latency.

Keywords: human activity recognition, adaptive music, IMU, smartwatch, CNN, HAR

Saturs

Apzīmējumu saraksts	6
Ievads	7
1 Esošie risinājumi	8
1.1 Adaptīvā mūzika.....	8
1.2 Adaptīvā mūzika treniņā.....	8
1.3 Vingrošanas noteikšana ar IMU sensoriem	9
1.4 Līdzīgi darbi vingrošanas noteikšanā	9
2 Metode.....	11
2.1 Sistēmas pārskats	11
2.2 Modelis	11
2.3 Slīdošais logs	12
2.4 Datu kopas un priekšapstrāde	13
2.5 Modeļa trenēšana	14
2.6 Pēcapstrādes algoritms	15
2.7 Datu ievākšanas protokols	16
2.8 Modeļa pielāgošana ar ievāktajiem datiem	17
2.9 Novērtēšana	18
3 Risinājuma realizācija.....	20
3.1 Viedpulksteņa lietotne	20
3.2 Telefona anotāciju lietotne.....	21
3.3 Sensoru datu ievākšana un klasifikācija	21
3.4 Laika zīmogu sinhronizācija.....	22
3.5 Adaptīvās mūzikas vadības prototips	22
4 Ievāktā datu kopa.....	24
5 Rezultāti uz publiskajām datu kopām.....	26
5.1 Modeļa rezultāti vienas datu kopas ietvaros.....	26
5.2 Vispārināšana starp datu kopām	26

5.3	Fragmentācija vingrošanas segmentos	27
5.4	Pēcapstrādes ietekme uz fragmentāciju	28
5.5	Loga izmērs un solis	29
6	Rezultāti uz ievāktu datu kopu	32
6.1	Kopējie klasifikācijas rezultāti	32
6.2	Muskuļu grupu un vingrinājumu pārklājums	33
6.3	Fragmentācija vingrošanas segmentos	35
6.4	Aizkave	38
6.5	Kļūdainās aktivizācijas nevingrojot	40
6.6	Kopsavilkums	41
7	Diskusija	43
8	Secinājumi	44
	Pateicība	46
	Izmantotā literatūra un avoti	47
	Pielikums	49
1.	pielikums	49

APZĪMĒJUMU SARAKSTS

HAR - Cilvēku aktivitāšu atpazīšana (Human Activity Recognition)

IMU - Inerces mērierīce; šajā darbā akselerometrs un žiroskops (Inertial Measurement Unit)

CNN - Konvolūciju neironu tīkls (Convolutional Neural Network)

IEVADS

Treniņu laikā mūzika tiek bieži izmantota, lai palielinātu motivāciju, uzlabotu sniegumu un padarītu treniņu patīkamāku. Tomēr mūzikas atskaņošana parasti nav saistīta ar pašu treniņa gaitu. Var gadīties, ka vingrinājuma laikā skan mierīga mūzika, bet atpūtas laikā sākas enerģiskāks dziesmas fragments.

Adaptīvās mūzikas sistēmas piedāvā iespēju mūziku pielāgot lietotāja vai sistēmas stāvoklim. Piemēram, videospēlēs mūzika var pielāgoties spēles notikumiem: sākoties cīņai, tiek atskaņots enerģiskāks mūzikas fragments, bet pēc tās beigām mūzika atgriežas mierīgākā stāvoklī. Līdzīgu pieeju varētu izmantot arī trenažieru zāles treniņā, kur vingrošanas sākums un beigas kalpotu kā notikumi mūzikas pielāgošanai.

Šim darbam nozīmīgs ir RISE [1] risinājums, kurā dziesmas struktūra tiek pārkārtota atbilstoši vingrošanas un atpūtas periodiem: vingrošanas laikā tiek atskaņoti enerģiskāki dziesmas fragmenti, bet atpūtas laikā mierīgāki fragmenti. Tomēr RISE sistēmā vingrošanas un atpūtas periodi tiek iegūti no manuālas ievades. Tādēļ paliek jautājums, vai šādus notikumus var noteikt automātiski reāllaikā.

Mūsdienu viedpulksteņos ir iebūvēti inerces sensori, piemēram, akselerometrs un žiroskops, kurus var izmantot cilvēku aktivitāšu atpazīšanai. Iepriekšējie pētījumi parāda, ka ar valkājamo IMU sensoru datiem ir iespējams atpazīt konkrētus spēka vingrinājumus un skaitīt atkārtojumus [2–6]. Šajā darbā tiek risināts vienkāršāks binārs uzdevums: noteikt, vai lietotājs konkrētajā brīdī vingro vai nevingro.

Šajā darbā tiek pētīts, vai viedpulksteņa IMU dati un binārs klasifikators var reāllaikā noteikt vingrošanu pietiekami labi, lai šādu signālu izmantotu treniņam adaptīvas mūzikas vadībai. Darba ietvaros tiek izveidots CNN modelis, kas apmācīts uz publiskajām RecoFit [3] un MyoGym [7] datu kopām un izvietots reāllaika darbībai uz Samsung Galaxy Watch 8 viedpulksteņa. Praktiskā eksperimenta veikšanai tiek izstrādāta arī telefona lietotne vingrinājumu sākuma un beigu anotācijai.

Darba praktiskajā daļā tiek veiktas reālas treniņu sesijas ar 10 dalībniekiem trenažieru zālē. Sistēmas darbība tiek novērtēta ne tikai pēc logu klasifikācijas rezultātiem, bet arī pēc adaptīvas mūzikas vadībai nozīmīgām īpašībām: vingrošanas noteikšanas aizkaves, segmentu fragmentācijas un kļūdainām aktivizācijām atpūtas laikā. Tādējādi darbs novērtē, vai iegūtais vingrošanas/ nevingrošanas signāls var būt praktiski izmantojams reāllaika adaptīvās mūzikas sistēmā.

1 ESOŠIE RISINĀJUMI

1.1 Adaptīvā mūzika

Adaptīvā mūzika ir mūzikas atskaņošanas pieeja, kurā atskaņojums mainās atbilstoši sistēmas vai lietotāja stāvoklim. Galvenokārt to izmanto videospēlēs, lai mūzika reaģētu uz spēles notikumiem [8], piemēram, cīņas sākumu, spriedzes pieaugumu vai pāreju uz citu vidi. Šādas sistēmas bieži izmanto horizontālo pārsekvencēšanu un vertikālo orķestrāciju [8, 9], kā arī var mainīt tempu, tonalitāti vai skaļumu.

Horizontālā pārsekvencēšana nozīmē pāreju starp dažādiem mūzikas segmentiem. Piemēram, tiek atkārtots viens mierīgs mūzikas segments, bet, sākoties cīņai, tiek pāriets uz enerģisku mūzikas segmentu. Savukārt vertikālā orķestrācija nozīmē atsevišķu mūzikas slāņu ieslēgšanu vai izslēgšanu. Piemēram, skaņdarbs var sastāvēt no vairākiem instrumentu slāņiem, un sistēma var tos pakāpeniski pievienot vai noņemt atkarībā no notikumiem. Treniņa kontekstā vingrošanas sākums un beigas var kalpot kā līdzīgi vadības notikumi, kas nosaka pāreju starp mierīgākiem un intensīvākiem mūzikas stāvokļiem.

1.2 Adaptīvā mūzika treniņā

Personalizētas interaktīvas mūzikas sistēmas izmanto reāllaika datus, lai pielāgotu mūziku lietotāja fiziskajai aktivitātei un uzlabotu treniņa pieredzi [10]. Šādi risinājumi ietver gan dziesmu rekomendāciju sistēmas, gan mūzikas struktūras vai intensitātes pielāgošanu treniņa laikā.

Skriešanas un soļošanas sistēmās mūziku bieži pielāgo kustības tempam, piemēram, saskaņojot dziesmas ritmu ar soļu ritmu vai sirds ritmu [11–13]. Trenažieru zāles kontekstā ir pētīti arī risinājumi, kuros mūzika tiek pielāgota pēc trenažiera vai sensora signāla intensitātes. Piemēram, Jymmin [14] sistēmā trenažieri tiek izmantoti kā mūzikas instrumenti, radot muzikālu atgriezenisko saiti lietotāja kustībām.

Cita pieeja ir mainīt mūzikas intensitāti atbilstoši slodzes intensitātei. Piemēram, Carôt u.c. [15] darbā mūzikas slāņi tiek ieslēgti vai izslēgti, izmantojot vienkāršus sliekšņus, kas balstīti uz trenažiera ātrumu vai akselerometra signāla kustības intensitāti. Šāda pieeja ļauj sasaistīt mūzikas intensitāti ar kustību intensitāti, tomēr arī nevingrošanas aktivitātes var ietvert intensīvas kustības.

Šim darbam īpaši nozīmīgs ir RISE [1] risinājums, kurā dziesmas struktūra tiek pārkārtota atbilstoši treniņa intensitātei. RISE izmanto vingrošanas un atpūtas notikumus, lai pārietu starp enerģiskākiem un mierīgākiem dziesmas fragmentiem. Tomēr šajā risinājumā vingrošanas sākums un beigas tiek ievadīti manuāli. Tādēļ paliek jautājums, vai šādus notikumus var iegūt automātiski, izmantojot valkājamo sensoru datus.

1.3 Vingrošanas noteikšana ar IMU sensoriem

Cilvēku aktivitāšu atpazīšana (HAR) ir uzdevums, kurā ar sensoru datiem tiek noteikts, kādu aktivitāti cilvēks veic. Valkājamie IMU sensori ir īpaši piemēroti reāllaika treniņa sistēmām, jo tie ir nelieli un jau iekļauti viedpulksteņos. Brennan u.c. sistemātiskais pārskats [2] parāda, ka ar valkājamiem IMU sensoriem, ir iespējams ar augstu precizitāti (>90%) klasificēt treniņu zāles vingrinājumus. Tomēr šī darba uzdevums nav pilna vingrinājumu atpazīšana, bet bināra vingrošanas un nevingrošanas noteikšana reāllaikā.


Treniņu zāles aktivitāšu atpazīšanā parasti tiek izdalīti trīs saistīti, bet atšķirīgi uzdevumi: vingrinājumu klasifikācija, segmentācija un atkārtojumu skaitīšana [3–5]. Vingrinājumu klasifikācijā nosaka konkrēto vingrinājuma tipu, segmentācijā nosaka, kuros laika posmos notiek vingrošana, bet skaitīšanā nosaka atkārtojumu skaitu. Šajā darbā galvenais ir vingrošanas noteikšanas vai segmentācijas uzdevums, jo adaptīvās mūzikas vadībai ir nepieciešami vingrošanas sākuma un beigu notikumi.

1.4 Līdzīgi darbi vingrošanas noteikšanā

RecoFit [3], MiLift [4] un uLift [5] ir īpaši nozīmīgi šim darbam, jo tie arī risina vingrošanas noteikšanu ar valkājamiem sensoriem. Tādēļ šo darbu uzdevums ir līdzīgs šī darba uzdevumam, tomēr atšķiras noteiktā vingrošanas segmenta izmantošanas veids. Šajos risinājumos segmentācija galvenokārt kalpo treniņa izsekošanai, vingrinājuma klasifikācijai vai atkārtojumu skaitīšanai. Šādā kontekstā sistēma var izmantot vairāku sekunžu logu, buferi vai pēc vingrošanas noteikšanas apskatīties atpakaļ, lai atrastu vingrošanas segmenta sākumu (*1.1. att.*).

Adaptīvās mūzikas vadības gadījumā situācija ir atšķirīga. Mūzikas sistēmai nepieciešams reāllaika vadības signāls, kuru var izmantot tikai no brīža, kad tas tiek iegūts. Ja vingrošana tiek noteikta vairākas sekundes pēc tās sākuma, mūzikas pāreja arī notiek ar šādu

aizkavi. Tāpēc šajā darbā vingrošanas noteikšana netiek vērtēta tikai kā segmentu atrašanas problēma, bet arī kā reāllaika signāla ģenerēšanas problēma. Šī iemesla dēļ būtiskas ir ne tikai logu klasifikācijas metrikas, bet arī sākuma aizkave, segmentu fragmentācija un kļūdainas aktivizācijas atpūtas laikā.



1.1. att. Slīdošā loga interpretācija reāllaika sistēmā. Atšķirībā no segmentēšanas pieejām, kur loga sākumu var izmantot kā aptuvenu segmenta sākumu pēc segmenta noteikšanas, šajā darbā klasifikācijas signāls kļūst pieejams tikai loga beigu brīdī, kad visi logā iekļautie sensora dati ir ievākti un sistēma ir to apstrādājusi.


Mekruksavanich un Jitpattanakul [16] darbs ir nozīmīgs šī darba modeļa izvēlei. Atšķirībā no RecoFit un MiLift, kuros tiek izmantotas manuāli veidotas pazīmes un klasiskās mašīnmācīšanās metodes, šajos darbos CNN tipa modeļi apgūst pazīmes tieši no IMU sensoru datu logiem. Lai gan šie darbi risina daudz klašu vingrinājumu atpazīšanu, to rezultāti parāda, ka CNN modelis spēj no IMU signāliem atpazīt vingrošanu. Tādēļ šajā darbā tiek pārbaudīts, vai CNN pieeju var izmantot binārai vingrošanas/nevingrošanas stāvokļa noteikšanai, kas pēc uzdevuma ir tuvāka RecoFit un MiLift segmentācijas posmam, bet neprasa manuālu pazīmju aprēķināšanu.

Tādējādi šī darba pieeja apvieno divas literatūrā redzamas idejas: RecoFit un MiLift līdzīgo vingrošanas/nevingrošanas noteikšanas uzdevumu un CNN spēju apgūt pazīmes tieši no IMU datu logiem. Tomēr atšķirībā no iepriekšējiem darbiem šeit noteiktais vingrošanas stāvoklis tiek vērtēts kā adaptīvās mūzikas vadības signāls, kuram jābūt pietiekami ātram un stabilam, lai to varētu izmantot mūzikas pāreju vadībai reāllaikā.

2 METODE

2.1 Sistēmas pārskats

Lai treniņa laikā varētu automātiski vadīt adaptīvu mūzikas sistēmu, ir nepieciešams reāllaikā noteikt, vai sportists pašlaik izpilda vingrinājumu vai atrodas atpūtas periodā. Šajā darbā šis uzdevums tiek formulēts kā bināra klasifikācija: “vingro” vai “nevingro”. Darba pamatideja parādīta 2.1. att.



2.1. att. Darba pamatideja: viedpulksteņa IMU dati tiek sadalīti slīdošos logos, klasificēti ar CNN modeli kā “vingro” vai “nevingro”, un iegūtais stāvokļa signāls var tikt izmantots adaptīvās mūzikas vadībai

Adaptīvās mūzikas sistēma šajā darbā netiek realizēta. Tā tiek izmantota kā motivācija, pēc kuras tiek vērtētas vingrošanas noteikšanas sistēmas prasības: reāllaika darbība, pietiekami maza aizkave un stabils vingrošanas/ nevingrošanas signāls.

Lai iegūtu šādu signālu, tiek izmantots viedpulkstenis ar inerces sensoriem. Viedpulkstenis ievāc akselerometra un žiroskopa datus, kas tiek sadalīti slīdošos laika logos. Katrs logs tiek klasificēts ar CNN modeli kā “vingro” vai “nevingro”. Modeļa izvade var tikt izmantota kā vadības signāls potenciālai adaptīvai mūzikas sistēmai: vingrošanas periodos sistēma var pāriet uz enerģiskāku mūziku, bet atpūtas periodos uz mierīgāku mūziku.

Galvenais mērķis ir iegūt pietiekami precīzu un stabilu reāllaika vingrošanas/nevingrošanas signālu, kas būtu izmantojams adaptīvās mūzikas vadībai, piemēram, tādā sistēmā kā RISE.

2.2 Modelis

Šajā darbā vingrošanas noteikšanai tiek izmantots konvolūciju neironu tīkls (CNN), kas klasificē IMU datu logus kā “vingro” vai “nevingro”. CNN modelis tika izvēlēts, jo iepriekšējie darbi rāda, ka šādi modeļi spēj atpazīt vingrinājumus akselerometra un žiroskopa laika rindās

[2]. Atšķirībā no klasiskām mašīnmācīšanās pieejām, CNN modelim nav nepieciešama manuāla pazīmju konstruēšana, jo konvolūciju slāņi var mācīties lokālas kustību pazīmes tieši no sensoru signāla.

Modeļa arhitektūra ir balstīta uz Mekruksavanich un Jitpattanakul [16] darbā izmantoto CNN-ResBiGRU pieeju, taču šajā darbā tiek izmantota vienkāršota CNN arhitektūra bez rekurentajiem slāņiem, kas darbā arī iegūst labus rezultātus, jo tas prasīs mazāk resursus uz viedpulksteņa.

Modelis sastāv no četriem konvolūciju blokiem. Katrs bloks satur vienas dimensijas konvolūciju slāni, batch normalization slāni, ReLU aktivāciju, max pooling slāni un dropout slāni. Konvolūciju bloku struktūra ir balstīta uz Mekruksavanich un Jitpattanakul [16] un ar to saistītajiem darbiem [6, 17]. Noslēgumā tiek izmantots pilnībā savienots slānis ar vienu neironu un sigmoid aktivāciju, kas dod varbūtību, ka ievades logs atbilst vingrošanai.

Modeļa ievade ir IMU datu logs ar izmēru 100×6 , kur 100 ir mērījumu skaits logā, bet 6 kanāli atbilst akselerometra un žiroskopa x, y un z asīm. Modeļa izvade ir skaitliska vērtība intervālā no 0 līdz 1. Ja šī vērtība pārsniedz 0,5 sliekšni, logs tiek klasificēts kā “vingro”; pretējā gadījumā tas tiek klasificēts kā “nevingro”.

2.1. tabula

Konvolūciju neirona tīkla slāņi

Slānis	Parametri
Input	100×6 IMU logs
Conv1D	32 filtri, kernel size 10, padding same
BatchNorm + ReLU + MaxPool + Dropout	pool size 2, dropout 0,25
Conv1D	64 filtri, kernel size 10, padding same
BatchNorm + ReLU + MaxPool + Dropout	pool size 2, dropout 0,25
Conv1D	64 filtri, kernel size 10, padding same
BatchNorm + ReLU + MaxPool + Dropout	pool size 2, dropout 0,25
Conv1D	32 filtri, kernel size 10, padding same
BatchNorm + ReLU + MaxPool + Dropout	pool size 2, dropout 0,25
GlobalAveragePooling1D	
Dense	1, sigmoid

2.3 Slīdošais logs

CNN modelis klasificē noteikta ilguma IMU datu logu, nevis atsevišķus sensora mērījumus. Šajā darbā galvenā konfigurācija ir 2 sekunžu slīdošais logs ar 1 sekundes soli. Tā kā dati tiek ievākti ar 50 Hz frekvenci, 2 sekunžu logs satur 100 mērījumu brīžus.

Ar 1 sekundes soli modelis veic vienu klasifikāciju sekundē, izmantojot pēdējās 2 sekundēs ievāktos datus. Klasifikācijas rezultāts tiek attiecināts uz loga beigu brīdi, jo tikai tad visi logā iekļautie dati ir pieejami. Tas ir būtiski reāllaika novērtēšanā, jo loga garums ietekmē reakcijas aizkavi.

Loga garums un solis veido kompromisu starp atpazīšanas kvalitāti, reakcijas ātrumu un resursu izmantošanu. Garāks logs var saturēt pilnīgāku kustības informāciju, bet palielina aizkavi. Mazāks solis ļauj iegūt biežākas klasifikācijas, bet palielina modeļa izpildes biežumu un var radīt fragmentētāku signālu.

Šajā darbā 2 sekunžu logs ar 1 sekundes soli tiek izvēlēts kā galvenā reāllaika konfigurācija. Papildus publisko datu kopu eksperimentos tiek salīdzināta arī 5 sekunžu loga un 200 ms soļa konfigurācija, jo līdzīgi parametri izmantoti RecoFit vingrošanas segmentēšanā [12]. Šis salīdzinājums ļauj novērtēt, vai garāks logs un biežāka klasifikācija uzlabo vingrošanas noteikšanu un kā tas ietekmē stabilitāti un aizkavi.

2.4 Datu kopas un priekšapstrāde

Lai apmācītu modeli atšķirt vingrošanas un atpūtas periodus, tika izmantotas divas publiskas treniņu zāles aktivitāšu datu kopas: RecoFit [12] un MyoGym [18]. Abas datu kopas satur anotētas treniņu sesijas ar vairākiem dalībniekiem un inerces sensoru datus no uz labās rokas novietotās sensoru aroces. Datu kopās ir pieejami akselerometra un žiroskopa mērījumi trīs asīs: x, y un z. Mērījumi ir ievākti ar 50 Hz frekvenci.

RecoFit ir būtiski lielāka datu kopa: tā satur 126 treniņu sesijas un 76 atšķirīgas aktivitāšu klases, no kurām 26 ir unikāli vingrinājumi. Datu kopā ir iekļautas gan dažādas viena vingrinājuma variācijas, gan nevingrošanas aktivitātes. MyoGym datu kopā piedalās 10 dalībnieki, un tajā ir 30 atšķirīgi vingrinājumi un viena nevingrošanas klase. Atšķirībā no RecoFit, MyoGym galvenokārt satur augšējās ķermeņa daļas vingrinājumus. Datu kopu izmērs un vingrošanas/nevingrošanas klašu proporcija ir parādīta 2.2. tabulā.

2.2. tabula

RecoFit un MyoGym datu kopu izmērs un vingrošanas proporcija

Datu kopa	Izmērs (h)	Rindu skaits	Vingrošana	Nevingrošana
RecoFit	79,4	14 295 605	32%	68%
MyoGym	8,9	1 608 998	23%	77%

Sākotnējās aktivitāšu anotācijas tika pārveidotas par binārām klasēm “vingro” un “nevingro”. MyoGym datu kopā visi 30 vingrinājumi tika apzīmēti kā “vingro”, bet nevingrošanas klase kā “nevingro”. RecoFit datu kopā kā “nevingro” tika apzīmētas klases, kas neatbilst vingrinājuma izpildei, piemēram, sākotnējā aktivitāte, aprocēs pielāgošana, ierīces aiztikšana, atpūta, staigāšana, skriešana, stiepšanās, nederīgi vai nezināmi segmenti un citas nevingrošanas aktivitātes. Pārējās RecoFit vingrinājumu klases tika apzīmētas kā “vingro”.

Pirms modeļa apmācības tika veikta mērvienību pārveidošana. RecoFit un MyoGym datu kopās akselerometra dati ir izteikti gravitācijas paātrinājuma vienībās g, bet žiroskopa dati grādos sekundē. Android sensoru dati savukārt tiek iegūti mērvienībās: akselerometram m/s^2 un žiroskopam rad/s. Lai publisko datu kopu dati atbilstu izpildes vides datiem, akselerometra vērtības tika reizinātas ar 9,81, bet žiroskopa vērtības ar $\pi/180$.


Pēc mērvienību pārveidošanas dati tika sadalīti slīdošos logos. Galvenajā konfigurācijā tika izmantots 2 sekunžu logs ar 1 sekundes soli, bet papildu eksperimentos tika izmantotas arī citas loga garuma un soļa konfigurācijas. Katram logam tika piešķirta binārā klase atbilstoši klasei, kas logā aizņem lielāko laika daļu. Ja logā lielākā daļa mērījumu atbilst vingrinājuma anotācijai, logs tika apzīmēts kā “vingro”, pretējā gadījumā tas tika apzīmēts kā “nevingro”.

2.5 Modeļa trenēšana

Pirms modeļa izvietošanas uz viedpulksteņa tika veikta modeļa apmācība un novērtēšana uz publiskajām RecoFit [3] un MyoGym [7] datu kopām. Šī posma mērķis bija pārbaudīt, vai izvēlēta CNN arhitektūra spēj atšķirt vingrošanas un nevingrošanas logus, kā arī novērtēt modeļa spēju vispārināt starp dažādām datu kopām. Modeļa apmācība tika veikta Kaggle vidē.

Modelis tika apmācīts un novērtēts trīs scenārijos: (1) apmācība un testēšana vienas datu kopas ietvaros; (2) apmācība uz vienas datu kopas un testēšana uz otras datu kopas; (3) apmācība un testēšana uz apvienotas RecoFit un MyoGym datu kopas.

Modeļa apmācības un novērtēšanas darba plūsma (2.2. att.): vispirms CNN modelis tiek apmācīts un novērtēts uz publiskajām RecoFit un MyoGym datu kopām, pēc tam apvienotais modelis tiek izmantots reāllaika eksperimentā uz viedpulksteņa; ievāktās treniņu sesijas tiek izmantotas sākotnējā modeļa novērtēšanai un modeļa pielāgošanas novērtēšanai.



2.2. att. Modeļa apmācības un novērtēšanas darba plūsma

Datu kopām testēšanas sadalījums tika veikts dalībnieku līmenī. Vispirms dalībnieki tika nejauši sadalīti apmācības un testēšanas grupās: aptuveni 80% dalībnieku tika iekļauti apmācības grupā, bet 20% testēšanas grupā. Pēc tam no apmācības grupas logiem tika nejauši atdalīti 20% validācijai.

Modeļa apmācības kontrolei tika izmantots validācijas PR-AUC (Precision-Recall Area Under the Curve) rādītājs. PR-AUC raksturo precizitātes un pārklājuma kompromisu pie dažādām klasifikācijas sliekšņa vērtībām. Šis rādītājs ir piemērots klašu nelīdzsvarotības gadījumā, jo tas raksturo pozitīvās klases “vingro” noteikšanas kvalitāti.

Gala novērtēšanā galvenā uzmanība tika pievērsta precizitātei, pārklājumam un F1 rādītājam, jo šie rādītāji tieši raksturo vingrošanas/ nevingrošanas klasifikācijas kvalitāti.

2.6 Pēcapstrādes algoritms

Tā kā modelis veic klasifikāciju katru sekundi, atsevišķas kļūdainas prognozes var radīt fragmentētu vingrošanas/nevingrošanas signālu. Adaptīvās mūzikas kontekstā tas varētu izraisīt nevēlamas un pārāk biežas mūzikas pārejas.

Lai novērtētu signāla stabilizēšanas iespēju, pēc ierakstu veikšanas klasifikāciju secībai tika pielietots akumulatora tipa pēcapstrādes algoritms. Algoritms netika izpildīts reāllaikā uz viedpulksteņa, bet izmantots analīzē.

Sākotnēji akumulators ir 0 un stāvoklis ir “nevingro”. Katrs “vingro” logs palielina akumulatoru par 1, bet katrs “nevingro” logs to samazina par 1. Vērtība tiek ierobežota intervālā no 0 līdz izvēlētajam sliekšnim. Stāvoklis pāriet uz “vingro”, kad akumulators sasniedz sliekšni, un atgriežas uz “nevingro”, kad akumulators samazinās līdz 0. Lielāks sliekšnis var samazināt fragmentāciju, bet palielināt vingrošanas sākuma un beigu noteikšanas aizkavi.

2.7 Datu ievākšanas protokols

Lai novērtētu vingrošanas noteikšanas pieeju reālā trenāžieru zāles vidē, tika veikts praktisks eksperiments ar dalībnieku treniņu sesijām. Eksperimenta mērķis bija pārbaudīt, vai uz viedpulksteņa darbināts modelis spēj reāllaikā noteikt vingrošanas un atpūtas periodus pietiekami labi, lai iegūtais signāls būtu potenciāli izmantojams adaptīvās mūzikas vadībai.

Eksperimenta laikā dalībnieki veica daļēji strukturētas treniņu sesijas, izmantojot Samsung Galaxy Watch 8 viedpulksteni uz labās rokas (2.3. att.). Dalībniekiem tika atļauts trenēties sev ierastā stilā un izvēlēties konkrētus vingrinājumus, taču tika noteikti vairāki nosacījumi, lai nodrošinātu minimālu vingrinājumu daudzveidību starp sesijām.




2.3. att. Eksperimenta dalībnieks ar Samsung Galaxy Watch 8 viedpulksteni uz labās rokas

Dalībniekiem tika prasīts izpildīt vismaz vienu vingrinājumu katrai no šādām muskuļu grupām: kājas, krūtis, mugura, pleci, tricepsi, bicepsi un vēders. Kāju vingrinājumiem tika prasīti vismaz divi vingrinājumi: viens pietupiena tipa vingrinājums un viens gūžas locīšanas jeb “hinge” tipa vingrinājums. Katrs vingrinājums tika veikts vismaz divos piegājienos ar 8-15 atkārtojumiem.

Eksperimentā apzināti netika iekļauti vingrinājumi, kuru noteikšana ar rokas IMU sensoriem varētu būt īpaši problemātiska. Netika iekļauti vienas rokas vingrinājumi un kāju izolācijas vingrinājumi, piemēram, kāju iztaisnošana trenāžierī (leg extensions). Šāds

ierobežojums tika izvēlēts, jo šajos vingrinājumos labās rokas kustība var nepietiekami raksturot vingrinājuma izpildi.

Eksperimenta laikā vingrinājumu piegājienu anotēšanai tika izmantota šī darba ietvaros izstrādāta telefona anotāciju lietotne (2.4. att.). Anotēšanu veica darba autors, atrodoties blakus dalībniekam treniņa laikā. Lietotnē tika atzīmēti katra vingrinājuma piegājiena sākuma un beigu laiki.



2.4. att. Darba ietvaros izstrādātās lietotnes. Kreisajā pusē: anotācijas lietotne; labajā pusē: viedpulksteņa lietotne.

Vingrinājuma sākums tika atzīmēts brīdī, kad dalībnieks ieņēma sākuma pozīciju un deva signālu par vingrinājuma sākšanu. Vingrinājuma beigas tika atzīmētas brīdī, kad dalībnieks pabeidza piegājienu un nolika svarus vai deva signālu par vingrinājuma beigām. Eksperimentā tika iekļauti arī vingrinājumi, kuri nebija izmantoti modeļa apmācībā uz publiskajām datu kopām. Tas ļāva novērtēt, vai modelis atpazīst tikai konkrētus apmācībā redzētus vingrinājumus vai arī vispārīgākas vingrošanai raksturīgas kustību īpašības.

2.8 Modeļa pielāgošana ar ievāktajiem datiem

Tā kā publiskās datu kopas atšķiras no šajā darbā ievāktajiem reālajiem viedpulksteņa datiem pēc izmantotās ierīces, dalībniekiem, vingrinājumiem, tika veikta modeļa pielāgošana ar ievāktajiem datiem. Uz RecoFit un MyoGym datu kopām apmācītais modelis tika izmantots kā sākotnējais modelis, kura svāri tika tālāk pielāgoti ar šajā darbā ievāktajām treniņu sesijām.


Modeļa pielāgošana tika novērtēta sesiju līmeņa shēmā. Katrā atkārtojumā viena no desmit sesijām tika atstāta testēšanai, viena cita sesija tika izmantota validācijai, bet atlikušās 8 sesijas tika izmantotas modeļa trenēšanai. Šī novērtēšanas shēma ļāva pārbaudīt, vai neliels mērķa domēna datu apjoms uzlabo vingrošanas noteikšanu reālos treniņu ierakstos.

2.9 Novērtēšana

Modeļa novērtēšana tika veikta divos līmeņos: logu klasifikācijas līmenī un anotēto vingrinājumu segmentu līmenī. Logu klasifikācijas līmenī katrs 2 sekunžu IMU datu logs tika salīdzināts ar tam piešķirto patieso klasi “vingro” vai “nevingro”. Segmentu līmenī tika vērtēts, vai klasifikāciju secība veido praktiski izmantojamu reāllaika stāvokļa signālu. Šāds novērtējums ir būtisks adaptīvās mūzikas vadības kontekstā, jo mūzikas pārejām svarīga ir ne tikai atsevišķu logu pareiza klasifikācija, bet arī signāla stabilitāte un reakcijas ātrums.

Logu klasifikācijas novērtēšanai tika izmantota precizitāte, pārklājums un F1 rādītājs. Precizitāte raksturo, cik liela daļa no logiem, kurus modelis klasificēja kā konkrētu klasi, patiešām atbilda šai klasei. Vingrošanas klases gadījumā tas nozīmē, cik liela daļa no modeļa noteiktajiem “vingro” logiem tiešām atradās vingrinājuma laikā. Pārklājums raksturo, cik liela daļa no visiem konkrētās klases logiem tika pareizi atpazīta. Vingrošanas klases gadījumā tas nozīmē, cik liela daļa no īstajiem vingrošanas logiem tika noteikta kā “vingro”. F1 apvieno precizitāti un pārklājumu vienā skaitlī. Īpaša uzmanība tika pievērsta vingrošanas klasei, jo adaptīvās mūzikas sistēmā neatpazīti vingrošanas logi var aizkavēt vai nepieļaut pāreju uz vingrošanai atbilstošu mūzikas stāvokli. Vienlaikus tika analizēti arī nevingrošanas klases rezultāti, jo kļūdaina vingrošanas stāvokļa noteikšana atpūtas laikā var radīt nevēlamas mūzikas pārejas.

Segmentu fragmentācija raksturo, cik atsevišķos prognozētajos “vingro” posmos tiek sadalīts viens anotēts vingrinājuma segments. Ideālā gadījumā vienam anotētam vingrinājuma segmentam atbilst viens nepārtraukts prognozētais “vingro” fragments. Ja segmentam netiek noteikts neviens “vingro” fragments, fragmentu skaits ir 0. Ja viena vingrinājuma laikā prognoze vairākas reizes pārslēdzas starp “vingro” un “nevingro”, fragmentu skaits palielinās. 2.5. att. ir redzams vingrošanas segments ar 3 fragmentiem. Adaptīvās mūzikas vadības kontekstā augsta fragmentācija ir nevēlama, jo tā var radīt pārāk biežas mūzikas stāvokļa maiņas viena piegājiena laikā.



2.5. att. Logu klasifikācijas signāla salīdzinājums ar anotēto vingrinājuma segmentu


Sākuma aizkave tika aprēķināta kā laika starpība starp anotētā vingrinājuma sākumu un pirmo prognozēto “vingro” stāvokli attiecīgajā segmentā. Pozitīva vērtība nozīmē, ka sistēma vingrošanu noteica pēc anotētā sākuma, bet negatīva vērtība nozīmē, ka sistēma aktivizējās pirms anotētā sākuma.

Kļūdainās aktivizācijas tika analizētas ārpus anotētajiem vingrinājumu segmentiem. Par kļūdainu aktivizāciju tika uzskatīts prognozēts “vingro” fragments laikā, kad pēc anotācijām dalībnieks neizpildīja vingrinājumu. Šiem fragmentiem tika aprēķināts aktivizāciju skaits, aktivizāciju biežums minūtē un aktivizāciju ilgums. Adaptīvās mūzikas kontekstā šis rādītājs raksturo risku, ka sistēma atpūtas laikā kļūdaini aktivizē enerģiskāku mūzikas stāvokli.

Šie rādītāji tika aprēķināti gan sākotnējā modeļa prognozēm, gan pielāgotā modeļa prognozēm, kā arī prognozēm pēc akumulatora pēcapstrādes.

3 RISINĀJUMA REALIZĀCIJA

Risinājums sastāv no divām Android lietotnēm un vēlākas datu analīzes procesa (3.1. att.). Viedpulksteņa lietotne reāllaikā ievāc IMU sensoru datus, uztur slīdošo logu un izpilda klasifikācijas modeli. Telefona lietotne tiek izmantota eksperimenta vadībai un vingrinājumu notikumu anotācijai. Pēc sesijas dati no abām ierīcēm tiek apvienoti analīzes vidē, kur anotācijas tiek salīdzinātas ar viedpulkstenī iegūtajām klasifikācijām. Darba pirmkods, datu apstrādes skripti un modeļu trenēšanas piezīmju grāmatas ir pieejamas darba GitHub repozitorijā [18].



3.1. att. Izstrādātā risinājuma sistēmas arhitektūra

3.1 Viedpulksteņa lietotne

Viedpulksteņa lietotne darbojas uz Samsung Galaxy Watch 8 un izmanto akselerometra un žiroskopa datus. Lietotne ievāc sensoru mērījumus ar 50 Hz frekvenci, uztur pēdējo 2 sekunžu sensoru datu logu un reizi sekundē padod šo logu klasifikācijas modelim. Klasifikācijas rezultāts tiek saglabāts kopā ar laika zīmogu un modeļa izvadīto varbūtību. Modelis ir konvertēts darbībai uz viedierīces TFLite formātā, izmantojot LiteRT [19], kas ļauj konvertēt modeļus priekš un darbināt mašīnmācīšanās modeļus uz iekārtām, kā telefoniem un mikrokontrolieriem.

3.2 Telefona anotāciju lietotne

Telefona lietotne tiek izmantota eksperimenta vadībai. Ar to tiek sākts un pabeigts treniņa ieraksts, kā arī atzīmēti vingrinājumu sākuma un beigu brīži. Sākot ierakstu telefonā, tiek nosūtīts signāls arī viedpulkstenim, lai abas ierīces sāktu datu ievākšanu vienā eksperimenta sesijā. Telefona lietotne izveido anotāciju failu JSON formātā, kurā katram notikumam tiek saglabāts nosaukums, sākuma laiks un beigu laiks. Laika zīmogi tiek saglabāti Unix laika formātā milisekundēs.

Viedpulksteņa lietotne katrai sesijai saglabā vairākus failus. Akselerometra un žiroskopa mērījumi tiek saglabāti atsevišķos failos, kuros katram ierakstam ir laika zīmogs un trīs ass vērtības. Atsevišķi tiek saglabāti arī modeļa klasifikācijas rezultāti: klasifikācijas laiks, modeļa izvadītā vērtība, binārais stāvoklis un klasificētais sensoru datu logs. Lai samazinātu rakstīšanas slodzi sesijas laikā, dati sākotnēji tiek uzkrāti buferos un tikai pēc bufera aizpildīšanās ierakstīti failā.

3.3 Sensoru datu ievākšana un klasifikācija

Android sistēmā akselerometra un žiroskopa mērījumi tiek saņemti kā atsevišķi sensoru notikumi. Praktiskajos testos tika novērots, ka šie mērījumi ienāk ļoti tuvu viens otram un parasti pamīšus. Tādēļ lietotnē tiek uzturētas pēdējās akselerometra un žiroskopa vērtības, un tālākai apstrādei sensoru pāris tiek izmantots tikai tad, kad ir saņemts gan akselerometra, gan žiroskopa mērījums. Šādi tiek izveidots viens apvienots IMU mērījums ar sešām vērtībām: akselerometra un žiroskopa x, y un z asīm.

Klasifikācijai tiek uzturēts 2 sekunžu apļa buferis. Tā kā sensoru dati tiek ievākti ar 50 Hz frekvenci, vienā logā ir 100 mērījumu brīži. Katram mērījumu brīdim tiek izmantotas sešas vērtības, tāpēc klasifikatoram padotais logs satur 100×6 vērtības. Reizi sekundē bufera saturs tiek nolasīts, sakārtots modeļa ievades formātā un padots CNN klasifikatoram.

Sākotnējos testos tika novērots, ka sensoru ievākšanas frekvence ne vienmēr saglabājas stabila. Kad viedpulksteņa ekrāns kļuva neaktīvs (tumšs), laika atšķirība starp secīgiem mērījumiem kļuva lielāka nekā paredzētās 20 ms. Lai nodrošinātu stabilu sensoru datu ievākšanu ar 50 Hz frekvenci visas sesijas laikā, lietotnē tika izmantots WakeLock [20] mehānisms. Pēc tā ieviešanas sensoru mērījumi saglabājās stabili visas ieraksta sesijas garumā.

3.4 Laika zīmogu sinhronizācija

Datu analīzei bija nepieciešams saskaņot vairākas laika līnijas. Vienas sesijas laikā tika izmantoti telefona laika zīmogi, viedpulksteņa laika zīmogi un sensoru notikumu laika zīmogi. Telefona laika līnijā tika saglabāts ieraksta sākums, beigas un vingrinājumu anotācijas. Viedpulksteņa laika līnijā tika saglabāts ieraksta sākums, beigas un klasifikācijas rezultāti. Savukārt sensoru notikumiem Android sistēma piešķir laika zīmogus nanosekundēs kopš ierīces palaišanas.

Tā kā telefona un viedpulksteņa sistēmas laiki var atšķirties par vairākām simtdaļām vai pat sekundēm, analīzes laikā telefona anotācijas tika konvertētas uz viedpulksteņa laika līniju. Šim nolūkam tika aprēķināta nobīde starp telefona un viedpulksteņa ieraksta sākuma laikiem: $nobīde = t_{\text{telefons}, \text{sākuma laiks}} - t_{\text{viedpulkstenis}, \text{sākuma laiks}}$. Pēc tam katrs anotācijas sākuma un beigu laiks tika pārrēķināts kā $t_{\text{viedpulkstenis}} = t_{\text{telefons}} - nobīde$. Tas ļāva salīdzināt telefona lietotnē anotētos vingrinājumu segmentus ar viedpulkstenī saglabātajiem klasifikācijas rezultātiem.

Šāda realizācija ļāva iegūt gan reāllaika modeļa prognozes no viedpulksteņa, gan neatkarīgas telefona anotācijas, kuras vēlāk tika izmantotas sistēmas precizitātes, aizkaves un stabilitātes novērtēšanai.

3.5 Adaptīvās mūzikas vadības prototips

Papildus sensoru datu ievākšanai un klasifikācijas rezultātu saglabāšanai viedpulksteņa lietotnē tika izveidots vienkāršs adaptīvās mūzikas vadības prototips. Tas izmanto vertikālās orķestrācijas pieeju, kurā pamata mūzikas slānis tiek atskaņots nepārtraukti, bet papildu intensitātes slāņa skaļums tiek mainīts atbilstoši modeļa prognozēm. Šāda pieeja atbilst adaptīvās mūzikas slāņu pārvaldības principam, kur mūzikas intensitāte tiek mainīta, pievienojot vai noņemot atsevišķus skaņas slāņus.

Prototipā tika izmantoti bezmaksas adaptīvās mūzikas slāņi no Blips.fm “Urban Assault” mūzikas pakas. Blips.fm apraksta savas pakas kā adaptīvai mūzikai paredzētas, tostarp vertikālai slāņu pārvaldībai.

Prototipā tika izmantoti divi sinhroni atkārtoti atskaņoti audio slāņi: pamata slānis un papildu intensitātes slānis. Pamata slānis tiek atskaņots nepārtraukti, savukārt papildu slāņa skaļums tiek pielāgots atbilstoši vingrošanas noteikšanas stāvoklim.

Lai samazinātu atsevišķu kļūdainu prognožu ietekmi uz mūzikas pārslēgšanos, prototipā tika izmantots darbā vērtētais akumulatora algoritms ar sliekšni 3. Ja modeļa prognoze pārsniedz 0,5 sliekšni, akumulatora vērtība tiek palielināta, bet pretējā gadījumā samazināta. Papildu mūzikas slānis tiek aktivizēts, kad akumulators sasniedz sliekšņa vērtību, un deaktivizēts, kad akumulators samazinās līdz 0. Skaļuma pāreja tiek veikta pakāpeniski 1 sekundes laikā, lai izvairītos no straujām mūzikas izmaiņām.


Tādējādi mūzikas slāņa vadība netiek balstīta uz vienu atsevišķu klasifikācijas rezultātu, bet uz stabilizētu vingrošanas/nevingrošanas stāvokļa signālu. Tas samazina nevēlamu un pārāk biežu mūzikas pārslēgšanos īslaicīgu kļūdainu prognožu dēļ.

Adaptīvās mūzikas prototips netika atsevišķi novērtēts ar lietotāju pētījumu, tāpēc tā kvalitāte netiek analizēta kā darba rezultāts. Tas kalpo kā tehniska demonstrācija, ka izveidotais reāllaika vingrošanas noteikšanas signāls var tikt tieši izmantots mūzikas slāņu vadībai uz viedpulksteņa.


4 IEVĀKTĀ DATU KOPA

Atbilstoši iepriekš aprakstītajam treniņu sesiju eksperimentam tika ievāktas 10 treniņu sesijas ar 10 dažādiem dalībniekiem. Ievāktās datu kopas kopējais ilgums ir 13 stundas un 19 minūtes, kas ir salīdzināms ar publiskās MyoGym datu kopas ilgumu aptuveni 11 stundām un 10 dalībniekiem. Tomēr klašu sadalījums būtiski atšķiras: ievāktajā datu kopā anotētie vingrošanas segmenti veido 118,62 minūtes jeb 14,84% no kopējā ilguma, kamēr MyoGym datu kopā vingrošanas segmenti veido 23%, bet RecoFit datu kopā 32%.

Sesiju ilgums bija no 37 minūtēm līdz 2 stundām un 9 minūtēm, ar vidējo ilgumu 1 stunda un 19 minūtes (4.1. att.). Kopumā tika anotēti 197 piegājieni 41 unikāliem vingrinājumiem, kas aptvēra 7 muskuļu grupas: vēderu, bicepsus, tricepsus, muguru, krūtis, kājas un plecus. Vidējais piegājiena ilgums bija 36 sekundes. Lielākā daļa piegājienu ilga aptuveni 25 līdz 45 sekundes (4.2. att.), tomēr tika novēroti arī atsevišķi būtiski garāki piegājieni.



4.1. att. Ievākto treniņu sesiju ilgums minūtēs



4.2. att. Anotēto vingrinājumu piegājienu ilguma sadalījums sekundēs

Vingrinājumu nosaukumi (4.1. tabula) saglabāti angļu valodā, jo publiskajās MyoGym un RecoFit datu kopās vingrinājumi ir apzīmēti angliski. Zīme “≈” norāda, ka publiskajā datu kopā ir līdzīgs, bet ne pilnībā ekvivalents vingrinājums. Atbilstība var nebūt pilnīga, jo var atšķirties izmantotais aprīkojums, ķermeņa pozīcija vai kustības trajektorija.

Eksperimentā izpildītie vingrinājumi un to atbilstība publiskajām datu kopām

Nosaukums	Grupa	Pozīcija	Aprīkojums	Piegājieni / dalībnieki	Ilgums (min)	MyoGym	RecoFit
Ab Crunch Machine	Vēders	Sēdus	Trenažieris	7 / 3	3,77	-	≈ Crunch / Sit-up
Ab Roll Outs	Vēders	Uz ceļiem	Rullis	1 / 1	0,12	-	-
Cable Ab Crunches	Vēders	Uz ceļiem	Kabelis	2 / 1	1,42	-	≈ Crunch / Sit-up
Crunches	Vēders	Guļus	-	6 / 4	5,34	-	Crunch / Sit-up
Leg Raises	Vēders	Karājoties	Plevilkšanās stienis	6 / 3	2,39	-	≈ V-up
Plank	Vēders	Balstā	-	2 / 1	1,58	-	Plank
Dumbbell Bicep Curls	Bicepsi	Stāvus	Hanteles	8 / 3	4,18	Dumbbell Alternate Bicep Curl	Bicep Curl
Hammer Curls	Bicepsi	Stāvus	Hanteles	4 / 2	2,25	Hammer Curl	≈ Bicep Curl
Incline Dumbbell Curls	Bicepsi	Sēdus slīpā solā	Hanteles, sols	4 / 2	3,36	≈ Incline Hammer Curl	≈ Bicep Curl
Preacher Curls	Bicepsi	Sēdus	Preacher sols, stienis	7 / 3	4,55	≈ Spider Curl / Concentration Curl	≈ Bicep Curl
Cable Overhead Extensions	Tricepsi	Stāvus	Kabelis	5 / 2	3,1	Overhead Triceps Extension	Overhead Triceps Extension
Dips	Tricepsi		Līdzekas	2 / 1	0,67	Bench Dip / Dip	Dip
Tricep Pushdowns	Tricepsi	Stāvus	Kabelis	17 / 7	9,66	Triceps Pushdown	-
Assisted Pull-ups	Mugura	Karājoties	Plevilkšanās trenažieris	2 / 1	1,7	≈ Wide-Grip Front Pulldown	-
Back Extensions	Mugura		Trenažieris	3 / 1	2,02	-	-
Cable Rows	Mugura	Sēdus	Kabelis	11 / 4	4,79	Seated Cable Rows	-
Lat Pulldowns	Mugura	Sēdus	Kabelis	6 / 3	4,04	Wide-Grip Front Pulldown	-
Pull-ups	Mugura	Karājoties	Plevilkšanās stienis	2 / 1	1,17	≈ Wide-Grip Front Pulldown	-
Row Machine	Mugura	Sēdus	Trenažieris	3 / 1	1,26	≈ Seated Cable Rows	-
Straight Arm Lat Pulldowns	Mugura	Stāvus	Kabelis	2 / 1	1,62	-	-
Bench Press	Krūtis	Guļus	Stienis, sols	9 / 3	3,57	Bench Press	Chest Press (rack)
Cable Chest Fly	Krūtis	Stāvus	Kabelis	4 / 1	2,25	≈ Dumbbell Flyes	-
Chest Fly Machine	Krūtis	Sēdus	Trenažieris	4 / 2	2,66	≈ Dumbbell Flyes	-
Chest Press Machine	Krūtis	Sēdus	Trenažieris	2 / 1	0,5	Leverage Chest Press	≈ Chest Press (rack)
Dumbbell Bench Press	Krūtis	Guļus	Hanteles, sols	5 / 2	4,28	≈ Incline Dumbbell Press	≈ Chest Press (rack)
Dumbbell Chest Flys	Krūtis	Guļus	Hanteles, sols	2 / 1	1,53	Dumbbell Flyes	-
Incline Dumbbell Bench Press	Krūtis	Guļus slīpā solā	Hanteles, sols	4 / 2	2	Incline Dumbbell Press	≈ Chest Press (rack)
Barbell Squats	Kājas	Stāvus	Stienis	6 / 3	2,92	-	Squat
Bulgarian Split Squat	Kājas	Stāvus	Hanteles, sols	7 / 2	6,59	-	≈ Lunge / Squat
Deadlifts	Kājas	Stāvus	Stienis	2 / 1	1,03	-	-
Goblet Squats	Kājas	Stāvus	Hantele / svaru bumba	10 / 5	5,28	-	Squat (kettlebell / goblet)
Lunges	Kājas	Stāvus	Hanteles	6 / 3	4,31	-	Lunge / Walking Lunge
Machine Deadlifts	Kājas	Stāvus	Trenažieris	3 / 1	2,07	-	-
Romanian Deadlifts	Kājas	Stāvus	Stienis / hanteles	4 / 2	3,02	-	-
Single Leg Romanian Deadlifts	Kājas	Stāvus uz vienas kājas	Hanteles / ķermeņa svars	2 / 1	1,94	-	-
Stiff-Leg Deadlifts	Kājas	Stāvus	Hanteles	5 / 2	3,83	-	-
Barbell Overhead Press	Peci	Stāvus	Stienis	2 / 1	1,11	≈ Seated Dumbbell Shoulder Press	Squat Rack Shoulder Press
Cable Lateral Raises	Peci	Stāvus	Kabelis	4 / 1	1,8	Side Lateral Raise	Lateral Raise
Dumbbell Lateral Raises	Peci	Stāvus	Hanteles	10 / 5	5,63	Side Lateral Raise	Lateral Raise
Dumbbell Overhead Press	Peci	Stāvus	Hanteles	4 / 2	2,45	Seated Dumbbell Shoulder Press	Shoulder Press (dumbbell)
Machine Lateral Raises	Peci	Sēdus	Trenažieris	2 / 1	0,86	≈ Side Lateral Raise	Lateral Raise

5 REZULTĀTI UZ PUBLISKAJĀM DATU KOPĀM

5.1 Modeļa rezultāti vienas datu kopas ietvaros

Ja modelis tiek apmācīts un testēts vienas datu kopas ietvaros, tas sasniedz labus rezultātus (5.1. tabula), kas norāda, ka izvēlētajā CNN arhitektūra spēj atšķirt no IMU logiem vingrošanu no nevingrošanas.

Apmācot un testējot modeli uz RecoFit datu kopas, vidējais F1 rādītājs ir 0,89. Modelis nedaudz labāk atpazīst nevingrošanas klasi nekā vingrošanas klasi: nevingrošanas pārklājums ir 0,93, bet vingrošanas pārklājums ir 0,86 (5.2. tabula). Tas nozīmē, ka daļa vingrošanas logu netiek atpazīta, kas reāllaika adaptīvās mūzikas sistēmā varētu radīt risku, ka vingrošanas daļa no vingrošanas perioda netiek noteikta.

MyoGym datu kopā modelis sasniedz augstāku rezultātu - vidējais F1 rādītājs ir 0,96. Vingrošanas klasei modelis iegūst augstu pārklājumu 0,97, bet vingrošanas precizitāte ir zemāka 0,91. Tas nozīmē, ka modelis labi atpazīst vingrošanas logus, taču daļu nevingrošanas logu kļūdaini klasificē kā vingrošanu. Adaptīvās mūzikas kontekstā tas varētu radīt risku, ka sistēma atsevišķos atpūtas brīžos kļūdaini aktivizē vingrošanas stāvokli.

5.2 Vispārināšana starp datu kopām

Rezultāti rāda asimetrisku vispārināšanu starp kopām:

1. apmācot uz RecoFit, modelis labi darbojas arī uz MyoGym;
2. apmācot uz MyoGym, modelis būtiski sliktāk darbojas uz RecoFit;
3. kombinēta apmācība uz RecoFit un MyoGym dod stabilākus rezultātus abās kopās.

5.1. tabula

Modeļa vidējais F1 rādītājs, apmācot un testējot uz dažādām datu kopām

Vidējais F1			
Apmācīts uz\ Testēts uz	RecoFit	MyoGym	RecoFit + MyoGym
RecoFit	0,89	0,85	0,89
MyoGym	0,60	0,96	0,63
RecoFit + MyoGym	0,88	0,94	0,89

Apmācot modeli uz RecoFit un testējot uz MyoGym, modelis saglabā salīdzinoši labu vingrošanas pārklājumu 0,83. Tomēr vingrošanas precizitāte samazinās līdz 0,69, kas nozīmē, ka modelis biežāk kļūdaini klasificē nevingrošanas logus kā vingrošanu. Adaptīvās mūzikas sistēmā tas varētu izpausties kā kļūdaina vingrošanas stāvokļa aktivizācija atpūtas laikā.

Savukārt, apmācot modeli uz MyoGym un testējot uz RecoFit, rezultāti būtiski pasliktinās. Vidējais F1 rādītājs ir tikai 0,60, bet vingrošanas pārklājums ir 0,29. Tas nozīmē, ka modelis neatpazīst lielu daļu RecoFit vingrošanas logu. Šāds rezultāts norāda uz vāju vispārināšanu uz plašāku vingrinājumu kopu. Iespējamais iemesls ir MyoGym datu kopas šaurāks vingrinājumu pārklājums, jo tajā dominē augšējās ķermeņa daļas vingrinājumi.

Apvienotā apmācība uz RecoFit un MyoGym nodrošina līdzsvarotāku rezultātu. Testējot uz RecoFit, F1 rādītājs samazinās tikai no 0,89 līdz 0,88, bet testējot uz MyoGym no 0,96 līdz 0,94. Tādējādi apvienotais modelis zaudē nelielu daļu rezultāta katras atsevišķās datu kopas ietvaros, bet iegūst labāku vispārināšanas spēju. Šī iemesla dēļ reāllaika eksperimentiem tika izvēlēts modelis, kas apmācīts uz apvienotās RecoFit un MyoGym datu kopas.

5.2. tabula

Modeļa klasifikācijas rezultāti, apmācot un testējot uz dažādām datu kopām

Apmācīts uz	Testēts uz	Precizitāte				Pārklājums				F1			
		Vidējais	Svērtais vidējais	Nevingro	Vingro	Vidējais	Svērtais vidējais	Nevingro	Vingro	Vidējais	Svērtais vidējais	Nevingro	Vingro
RecoFit	RecoFit	0,89	0,90	0,93	0,85	0,89	0,90	0,93	0,86	0,89	0,90	0,93	0,86
RecoFit	MyoGym	0,83	0,91	0,96	0,69	0,87	0,90	0,92	0,83	0,85	0,90	0,94	0,75
RecoFit	RecoFit + MyoGym	0,89	0,90	0,93	0,84	0,89	0,90	0,93	0,86	0,89	0,90	0,93	0,85
MyoGym	RecoFit	0,66	0,68	0,72	0,60	0,60	0,70	0,90	0,29	0,60	0,66	0,80	0,39
MyoGym	MyoGym	0,95	0,98	0,99	0,91	0,98	0,98	0,98	0,97	0,96	0,98	0,99	0,94
MyoGym	RecoFit + MyoGym	0,69	0,71	0,75	0,64	0,62	0,73	0,91	0,34	0,63	0,70	0,82	0,44
RecoFit + MyoGym	RecoFit	0,88	0,89	0,92	0,84	0,88	0,89	0,92	0,84	0,88	0,89	0,92	0,84
RecoFit + MyoGym	MyoGym	0,92	0,96	0,99	0,86	0,96	0,96	0,96	0,95	0,94	0,96	0,98	0,90
RecoFit + MyoGym	RecoFit + MyoGym	0,89	0,90	0,93	0,84	0,89	0,90	0,93	0,85	0,89	0,90	0,93	0,85

5.3 Fragmentācija vingrošanas segmentos

Rezultāti parāda, ka segmentācijas fragmentācija būtiski atšķiras starp datu kopām (5.3. tabula). MyoGym datu kopā 90,0% vingrošanas segmentu tiek noteikti kā viens nepārtraukts fragments, un tikai 3,3% segmentu tiek sadalīti vismaz trīs fragmentos. Savukārt RecoFit datu kopā tikai 54,9% segmentu tiek noteikti kā viens fragments, bet 28,7% segmentu tiek sadalīti vismaz trīs fragmentos. Tas norāda, ka RecoFit šim binārās vingrošanas noteikšanas uzdevumam ir sarežģītāka datu kopa.

Datu kopu atšķirība vingrošanas segmentu fragmentācijā

Novērtējums	MyoGym	RecoFit	MyoGym+RecoFit
Segmenti ar 1 fragmentu (%)	90,0	54,9	54,2
Segmenti ar ≥ 3 fragmentiem (%)	3,3	28,7	29,2
Vidējais fragmentu skaits	1,3	3,2	3,0
Maksimālais fragmentu skaits	11	46	43

5.4 Pēcāpstrādes ietekme uz fragmentāciju

Lai samazinātu īslaicīgas pārslēgšanās starp vingrošanas un nevingrošanas stāvokļiem, tika pārbaudīta pēcāpstrādes ietekme ar “akumulatoru” ar diviem sliekšņiem (5.4. tabula).

Pēcāpstrādē ar “akumulatoru” tiek izmantots skaitītājs, kas palielinās, ja modelis prognozē vingrošanu, un samazinās, ja modelis prognozē nevingrošanu. Kad skaitītājs sasniedz izvēlēto sliekšni, sistēma pāriet vingrošanas stāvoklī. Savukārt, kad skaitītājs samazinās līdz 0, sistēma pāriet nevingrošanas stāvoklī.

Pēcāpstrādes mērķis ir stabilizēt vingrošanas segmentus, taču šāda pieeja neizbēgami palielina stāvokļa maiņas aizkavi.

Agregācijas sliekšņa ietekme uz segmentācijas fragmentāciju un aizkavi

Novērtējums	Apvienotais modelis	Sliekšnis 3	Sliekšnis 6
Vingrošanas segmenti ar 1 fragmentu (%)	54	80	88
Vidējais fragmentu skaits vingrošanas segmentā	3	1,2	0,96
Mediānā sākuma aizkave (s)	1,98	3,98	6,98
Vidējais kļūdaino aktivizāciju skaits minūtē	1,9	1,36	1,34
Vidējais kļūdaino aktivizāciju ilgums (s)	3,27	5,81	8,83

Vidējais fragmentu skaits aprēķināts pret visiem anotētajiem vingrošanas segmentiem, tāpēc nenoteikti segmenti var samazināt vidējo vērtību zem 1.

Rezultāti parāda, ka agregācija būtiski samazina vingrošanas segmentu fragmentāciju. Segmentu īpatsvars ar vienu fragmentu palielinās no 54,17% bāzes konfigurācijā līdz 80,39%

pie sliekšņa 3 un 88,24% pie sliekšņa 6. Vienlaikus vidējais fragmentu skaits samazinās no 3,0 līdz 1,2 un 0,96. Tas norāda, ka agregācija veiksmīgi stabilizē vingrošanas/nevingrošanas stāvokļa noteikšanu.

Tomēr stabilitātes uzlabojums tiek iegūts uz aizkaves rēķina. Mediānā sākuma aizkave pieaug no 1,98 s līdz 3,98 s pie sliekšņa 3 un līdz 6,98 s pie sliekšņa 6. Turklāt, lai gan kļūdaino aktivizāciju skaits minūtē samazinās, to vidējais ilgums palielinās. Tas nozīmē, ka agregācija samazina īsu kļūdainu aktivizāciju skaitu, bet atlikušās kļūdainās aktivizācijas kļūst ilgākas.

Adaptīvās mūzikas kontekstā sliekšnis 3 ir praktiskāks kompromiss nekā sliekšnis 6, jo tas būtiski uzlabo segmentu stabilitāti, bet saglabā zemāku sākuma aizkavi. Sliekšnis 6 nodrošina vēl stabilākus segmentus, taču gandrīz 7 sekunžu mediānā sākuma aizkave var būt pārāk liela reāllaika mūzikas pielāgošanai.

Līdzīga tendence tika novērota arī 5 sekunžu loga konfigurācijām: agregācija samazināja fragmentāciju, bet vēl vairāk palielināja sākuma aizkavi. Tā kā 5 sekunžu logam jau bez agregācijas ir lielāka sākuma aizkave (5.5. *tabula*), agregācijas izmantošana šai konfigurācijai ir mazāk piemērota reāllaika adaptīvās mūzikas vadībai. 200 ms solis nekompensēja šo aizkaves pieaugumu un nedevis būtisku stabilitātes ieguvumu salīdzinājumā ar 1 s soli, tāpēc reāllaika konfigurācijai tika izvēlēts 2 sekunžu logs ar 1 sekundes soli.

5.5 Loga izmērs un solis

Lai novērtētu loga garuma un klasifikācijas soļa ietekmi, tika ar kombinēto modeli salīdzinātas četras konfigurācijas: 2 sekunžu un 5 sekunžu logs ar 1 sekundi un 200 ms soli (5.5. *tabula*, 5.6. *tabula*). Klasifikācijas līmenī tika vērtēta vingrošanas klases precizitāte, pārklājums un vidējais F1, savukārt segmentācijas līmenī tika vērtēta fragmentācija, prognozēto segmentu skaits, aizkave un kļūdainās aktivizācijas atpūtas segmentos.

Loga garuma un soļa ietekme uz klasifikācijas un segmentācijas rezultātiem

Konfigurācija	2s logs, 1s solis	2s logs, 200ms solis	5s logs, 1s solis	5s logs, 200ms solis
Vingrošanas precizitāte	0,84	0,84	0,88	0,88
Vingrošanas pārklājums	0,85	0,85	0,88	0,88
Vidējais F1	0,89	0,89	0,91	0,91
Vingrošanas segmenti ar 1 fragmentu (%)	54	45	70	64
Vidējais fragmentu skaits vingrošanas segmentā	3,0	5,2	1,8	3,0
Faktiskais segmentu skaits	408	408	408	408
Prognozētais segmentu skaits	1989	3563	1096	1879
Mediānā sākuma aizkave (s)	1,98	1,78	4,98	4,58
Mediānā beigu aizkave (s)	1,00	0,00	1,00	0,20
Vidējais kļūdaino aktivizāciju skaits minūtē	1,9	3,5	1,3	2,2
Vidējais kļūdaino aktivizāciju ilgums (s)	3,3	1,8	3,7	2,3

Loga garuma un soļa konfigurāciju interpretācija adaptīvās mūzikas kontekstā

Konfigurācija	Klasifikācijas līmenis	Segmentācijas līmenis	Interpretācija
2s logs, 1 s solis	Nedaudz zemāks F1	Zemāka aizkave, vidēja fragmentācija	Labāks reāllaika reakcijai
2s logs, 200 ms solis	Līdzīgs F1, kā 2s / 1s	Lielāka fragmentācija un vairāk prognozēto segmentu	Mazāks solis palielina troksni
5s logs, 1 s solis	Labākais F1	Vismazāk fragmentācijas un mazāk kļūdaino aktivizāciju, bet lielāka aizkave	Stabilākais, bet lēnāks
5s logs, 200 ms solis	Līdzīgs F1 kā 5s/ 1s	Nedaudz stabilāks par 2s/ 1s, bet lielāka sākuma aizkave	Stabils, bet lēnāks

Salīdzinājums parāda, ka 5 sekunžu logs dod labākus klasifikācijas rezultātus un stabilākus segmentus nekā 2 sekunžu logs. Kombinētajā datu kopā 5 sekunžu logs ar 1 s soli palielina vidējo F1 no 0,89 līdz 0,91, samazina vidējo fragmentu skaitu no 3,0 līdz 1,8 un samazina prognozēto segmentu skaitu no 1989 līdz 1096. Tomēr šis uzlabojums tiek iegūts uz lielākas sākuma aizkaves rēķina: mediānā sākuma aizkave pieaug no 1,98 s līdz 4,98 s.

Savukārt soļa samazināšana līdz 200 ms neuzlabo klasifikācijas rezultātus, bet palielina segmentācijas troksni. Gan 2 sekunžu, gan 5 sekunžu loga gadījumā 200 ms solis rada vairāk prognozēto segmentu un lielāku vidējo fragmentu skaitu. Tādēļ šī darba kontekstā piemērotāks ir 1 s solis.

Lai gan 5 sekunžu logs sasniedz augstākus klasifikācijas un stabilākus segmentācijas rezultātus, reāllaika eksperimentam tika izvēlēts 2 sekunžu logs ar 1 sekundes soli. Šī konfigurācija nodrošina zemāku sākuma aizkavi, mazāku ievades buferi un retāku modeļa izpildi nekā 5 sekunžu logs ar 200 ms soli. Pie 50 Hz 2 sekunžu logs satur 100 mērījumus, bet 5 sekunžu logs satur 250 mērījumus. Savukārt 200 ms solis nozīmē modeļa izpildi piecas reizes sekundē, salīdzinot ar vienu reizi sekundē 1 s soļa gadījumā. Tā kā sistēma paredzēta darbībai uz viedpulksteņa, šie faktori ir būtiski akumulatora patēriņam, atmiņas izmantojumam un reāllaika reakcijai.

6 REZULTĀTI UZ IEVĀKTO DATU KOPU

6.1 Kopējie klasifikācijas rezultāti

Sākotnējais modelis, kas tika apmācīts tikai uz publiskajām RecoFit un MyoGym datu kopām, tika darbināts reāllaikā uz viedpulksteņa, klasificējot katru 2 sekunžu sensoru datu logu reizi sekundē. Uz treniņu sesijām modeļa klasifikācijas uz viedpulksteņa sasniedza vidējo F1 rādītāju 0,76 (6.1. tabula). Tomēr vingrošanas klases rezultāti bija būtiski zemāki nekā nevingrošanas klasei: vingrošanas precizitāte bija 0,57, pārklājums 0,63. Tas norāda, ka modelis spēj atpazīt daļu vingrošanas periodu, taču ar publiskajām datu kopām vien nepietiek, lai tas pietiekami labi vispārinātu uz šī darba viedpulksteni un trenažieru zāles treniņu vidi.

Papildus tika pārbaudīts, vai modeļa konvertēšana uz TFLite formātu un darbība uz viedpulksteņa ietekmē klasifikācijas rezultātus. Salīdzinot viedpulkstenī iegūtās prognozes ar sākotnējā Keras modeļa prognozēm uz tiem pašiem logiem, atšķirības netika novērotas. Tādējādi secināms, ka rezultātu kritums nav saistīts ar modeļa izvietojumu uz ierīces, bet gan ar atšķirību starp publiskajām apmācības datu kopām un reālo eksperimenta vidi.

Pēc modeļa pielāgošanas ar ievāktajām treniņu sesijām rezultāti būtiski uzlabojās. Vingrošanas pārklājums palielinājās no 0,63 līdz 0,82, bet vidējais F1 rādītājs pieauga no 0,76 līdz 0,86. Tas liecina, ka apmācība uz pielietojuma vides datiem ļauj modelim labāk atpazīt vingrošanas periodus dotajā vidē. Tomēr vingrošanas precizitāte joprojām saglabājās zemāka nekā nevingrošanas klasei. Tas nozīmē, ka daļa atpūtas logu vēl arvien tiek kļūdaini klasificēti kā vingrošana.

Lai samazinātu īslaicīgas pārslēgšanās starp stāvokļiem, tika izvērtēta arī pēcapstrāde ar akumulatora algoritmu. Pielāgotajam modelim akumulators ar sliekšni 3 uzlaboja vingrošanas precizitāti no 0,72 līdz 0,76, zaudējot neredz pārklājumu no 0,82 uz 0,81. Tas parāda, ka pēcapstrāde spēj samazināt daļu trokšņaino kļūdaino aktivizāciju, nezaudējot vingrošanas periodu noteikšanas spēju. Tika pārbaudīts arī sliekšnis 6, tomēr tas deva sliktākus klasifikācijas rezultātus nekā sliekšnis 3 un vienlaikus radīja vēl lielāku aizkavi.


Klasifikācijas rezultātu salīdzinājums uz ievāktu datu kopu

Modelis	Precizitāte (vingro)	Pārklājums (vingro)	F1 (vingro)	F1 (nevingro)	Vidējais F1
Sākotnējais	0,57	0,63	0,6	0,92	0,76
Pielāgotais	0,72	0,82	0,77	0,95	0,86
Sākotnējais ar sliekšni 3	0,66	0,61	0,63	0,94	0,79
Pielāgotais ar sliekšni 3	0,76	0,81	0,78	0,96	0,87
Pielāgotais ar sliekšni 6	0,74	0,75	0,75	0,95	0,85

6.2 Muskulu grupu un vingrinājumu pārklājums

Lai novērtētu, vai modelis vienādi labi atpazīst dažāda veida vingrinājumus kā vingrošanu, tika aprēķināts vingrinājumu segmentu pārklājums pa muskuļu grupām un atsevišķiem vingrinājumiem. Šajā sadaļā pārklājums nozīmē, cik liela daļa logu no anotētā vingrinājuma segmenta tika klasificēta kā vingrošana.

Muskuļu grupu rezultāti parāda, ka sākotnējais modelis dažādas muskuļu grupas atpazīst nevienmērīgi. Vislabāk tika atpazīti bicepsu, kāju un tricepsu vingrinājumi, kuru pārklājums jau sākotnējam modelim pārsniedza 70%. Savukārt plecu, krūšu un muguras vingrinājumi sākotnējam modelim bija būtiski grūtāki. Pēc modeļa pielāgošanas pārklājums uzlabojās visās muskuļu grupās. Lielākie uzlabojumi bija muguras, krūšu un plecu vingrinājumiem (6.1. att.).




6.1. att. Muskulu grupu kopējais pārklājums sākotnējam un pielāgotajam modelim

Tomēr muskuļu grupu vidējie rezultāti neparāda visas atšķirības starp sesijām. Eksperimentā dalībnieki varēja brīvi izvēlēties konkrētos muskuļu grupu vingrinājumus un to

izpildījuma veidu, tāpēc vienas muskuļu grupas rezultāti dažādās sesijās ne vienmēr attiecas uz vienādiem vingrinājumiem.

Kā redzams 6.2. att., daļa zema pārklājuma gadījumu ir saistīta ne tikai ar muskuļu grupu, bet arī ar konkrētu dalībnieku. Piemēram, sākotnējam modelim pirmajā sesijā plecu vingrinājumu pārklājums bija 92,1%, bet vairākās citās sesijās tas bija ļoti zems. Līdzīgi arī krūšu un muguras vingrinājumiem dažās sesijās pārklājums bija labs, bet citās gandrīz netika noteikta vingrošana. Pēc pielāgošanas šīs atšķirības samazinājās, tomēr pilnībā nepazuda. Tas norāda, ka modeļa veikspēju ietekmē ne tikai vingrinājuma muskuļu grupa, bet arī konkrētais vingrinājums un izpildījuma veids.




6.2. att. Muskuļu grupu pārklājums pa sesijām sākotnējam un pielāgotajam modelim

Vingrinājumu līmeņa rezultāti parāda, ka vienas muskuļu grupas ietvaros var būt gan ļoti labi, gan ļoti slikti atpazīstami vingrinājumi. Piemēram, krūšu vingrinājumu grupā pēc pielāgošanas labi tika atpazīti “Dumbbell Chest Flys”, “Bench Press”, “Incline Dumbbell Bench Press”, “Dumbbell Bench Press”, “Chest Fly Machine”, kuru pārklājums pārsniedza 90%. Savukārt “Cable Chest Fly” un “Chest Press Machine” arī pēc pielāgošanas saglabāja zemu pārklājumu (6.3. att.). Tātad zems muskuļu grupas vidējais pārklājums ne vienmēr nozīmē, ka modelis slikti atpazīst visus šīs grupas vingrinājumus.

Ir vingrinājumi, kuru pārklājums pēc pielāgošanas būtiski pieaug, piemēram, “Row Machine”, “Lat Pulldowns”, “Pull-ups” un “Dumbbell Overhead Press” (1. pielikums). Vienlaikus ir vingrinājumi, kuri arī pēc pielāgošanas saglabājas grūti atpazīstami, piemēram, “Cable Chest Fly”, “Chest Press Machine” un “Dips”. Dažos gadījumos pārklājums pēc pielāgošanas arī samazinās, piemēram, “Plank”. Tas parāda, ka pielāgošana uzlabo kopējo rezultātu, bet negarantē uzlabojumu katram atsevišķam vingrinājumam.

Augsts pārklājums tika novērots arī vairākiem vingrinājumiem, kuri nebija tieši iekļauti publiskajās apmācības datu kopās. Piemēram, vilkmes vingrinājumi “Romanian Deadlifts”,

“Single Leg Romanian Deadlifts” un “Stiff-Leg Deadlifts” sasniedza augstu pārklājumu jau sākotnējam modelim. Tas varētu būt skaidrojams ar kustību līdzību kāju vingrinājumu grupā, jo publiskajās datu kopās jau bija iekļauti pietupieni un izklupieni. Piemēram, izklupiena varianti, kuros dalībnieks sper soli atpakaļ, pēc rokas kustības un ķermeņa pozīcijas maiņas var būt līdzīgi atsevišķiem vilkmes tipa vingrinājumiem.



6.3. att. Krūšu vingrinājumu pārklājums sākotnējam un pielāgotajam modelim


Kopumā rezultāti rāda, ka modeļa pielāgošana būtiski uzlabo vingrošanas noteikšanu dažādās muskuļu grupās, īpaši tajās, kur sākotnējais modelis darbojās vāji. Tomēr vingrinājumu līmeņa analīze parāda, ka sistēmas veiktspēja nav vienāda visiem vingrinājumiem. Adaptīvās mūzikas kontekstā tas nozīmē, ka sistēma daudzos gadījumos var nodrošināt pietiekamu vingrošanas noteikšanu, bet atsevišķiem vingrinājumiem var būt nepieciešami papildu dati, pielāgošana vai pēcapstrāde, lai stāvokļa signāls būtu pietiekami drošs un stabils.

6.3 Fragmentācija vingrošanas segmentos

Vingrošanas segmentu fragmentācija raksturo, cik daudz atsevišķos vingrošanas fragmentos tiek sadalīts viens anotēts vingrinājuma segments. Ideālā gadījumā vienam vingrinājuma segmentam atbilst viens nepārtraukts vingrošanas fragments. Ja fragmentu skaits ir 0, tad anotētais segments vispār nav noteikts, savukārt lielāks fragmentu skaits norāda uz nestabilu klasifikāciju. Adaptīvās mūzikas kontekstā augsta fragmentācija nozīmētu biežas un nevēlamas pārslēgšanās starp vingrošanas un nevingrošanas stāvokļiem viena piegājiena laikā.

Rezultāti parāda, ka sākotnējais modelis ir izteikti trokšņains. Tikai 27,14% vingrošanas segmentu tika noteikti kā viens fragments, bet 51,43% segmentu tika sadalīti vismaz trīs

fragmentos. Vidējais fragmentu skaits vienā vingrošanas segmentā bija 3,59, bet maksimālais sasniedza 16 fragmentus (6.2. tabula, 6.4. att.). Tas norāda, ka sākotnējais modelis bieži pārslēdzas starp stāvokļiem arī viena vingrinājuma laikā.



6.4. att. Vingrošanas segmentu fragmentācijas sadalījums


Modeļa pielāgošana samazināja fragmentāciju, tomēr ar to vien nepietika, lai vairumā gadījumu iegūtu stabilu viengabala segmentu. Pēc pielāgošanas segmentu ar vienu fragmentu īpatsvars pieauga no 25,38% līdz 54,31%, savukārt segmentu ar vismaz trim fragmentiem īpatsvars samazinājās no 56,35% līdz 25,38%. Vidējais fragmentu skaits samazinājās no 3,91 līdz 2,61. Tātad pielāgošana būtiski uzlaboja rezultātu, bet klasifikācija joprojām daudzās gadījumos saglabājās nestabila.

Vislabākais rezultāts tika sasniegts, pielāgotajam modelim izmantojot akumulatoru ar sliekšni 3 (6.2. tabula). Šajā gadījumā 78,68% vingrošanas segmentu tika noteikti kā viens fragments, bet segmentu ar vismaz trim fragmentiem īpatsvars samazinājās līdz 2,03%. Vidējais fragmentu skaits samazinājās līdz 1,05, bet maksimālais fragmentu skaits nepārsniedza 4. Tas parāda, ka akumulators būtiski stabilizē vingrošanas/nevingrošanas stāvokļa signālu un daudzās gadījumos ļauj vienu anotētu vingrinājumu atspoguļot kā vienu nepārtrauktu vingrošanas segmentu.

Vingrošanas segmentu fragmentācijas rādītāji


Metrika	Sākotnējais	Pielāgotais	Pielāgotais ar sliekšni 3
Vingrošanas segmenti ar 1 fragmentu (%)	25,38	54,31	78,68
Vingrošanas segmenti ar ≥ 3 fragmentiem (%)	56,35	25,38	2,03
Vidējais fragmentu skaits vingrošanas segmentā	3,91	2,34	1,05
Maksimālais fragmentu skaits	16	13	4

Tomēr uzlabojumi nebija pilnīgi vienādi visās sesijās. Kā redzams 6.5. att., daļā sesiju pielāgotais modelis jau pats par sevi sasniedza salīdzinoši labu segmentu ar vienu fragmentu īpatvaru, bet citās sesijās būtisks uzlabojums tika iegūts tikai pēc akumulatora izmantošanas. Tas liecina, ka pielāgošana uzlabo segmentu kvalitāti, taču pēcapstrāde ir svarīga, lai iegūtu stabilāku signālu dažādās treniņu sesijās.



6.5. att. Vingrošanas segmenti ar vienu fragmentu pa sesijām

Šo efektu ilustrē arī 6.6. att. dotais piemērs, kur redzams, ka bez pēcapstrādes viens anotēts vingrošanas segments tiek sadalīts vairākos īsos fragmentos, bet akumulators šīs īslaicīgās pārslēgšanās izlīdzina un veido vienu stabilāku segmentu. Adaptīvās mūzikas kontekstā tas ir būtiski, jo stabilāks signāls samazina risku, ka mūzika viena piegājiena laikā tiks pārslēgta pārāk bieži.



6.6. att. Vingrošanas segmenta fragmentācijas piemērs un akumulatora ietekme

6.4 Aizkave

Aizkave raksturo, cik ātri sistēma nosaka vingrošanas stāvokļa sākumu vai beigas attiecībā pret anotēto vingrinājuma segmentu. Sākuma aizkave tika aprēķināta kā laika starpība starp anotēto vingrinājuma sākumu un pirmo noteikto vingrošanas stāvokli. Adaptīvās mūzikas kontekstā sākuma aizkave ietekmē to, cik ātri pēc vingrinājuma uzsākšanas varētu sākties enerģiskāka mūzika.


Sākotnējam modelim mediānā sākuma aizkavei bija 0,98 s, bet pielāgotajam modelim tā samazinājās līdz 0,72 s (6.3. tabula). Tas nozīmē, ka tipiskā gadījumā modelis vingrošanu noteica aptuveni vienas sekundes laikā pēc anotētā vingrinājuma sākuma. Ņemot vērā, ka ievāktajā datu kopā vidējais vingrinājuma piegājiena ilgums bija 36 sekundes, šāda mediānā aizkave ir salīdzinoši neliela. Tomēr aizkaves sadalījumā bija arī garāki gadījumi: sākotnējam modelim 95. procentile bija 9,70 s, bet pielāgotajam modelim 3,68 s. Tas norāda, ka pielāgošana samazināja ne tikai tipisko aizkavi, bet arī daļu no garo aizkavju gadījumiem.

Vingrošanas sākuma noteikšanas aizkaves rādītāji

Metrika	Sākotnējais	Pielāgotais	Pielāgotais ar sliekšni 3
Mediāna (s)	0,98	0,71	2,62
Vidējais (s)	2,02	0,63	1,35
95. procentile (s)	9,70	3,68	7,17
Aizkave ≤ 3 s (%)	74,33	80,73	46,37
Aizkave ≤ 5 s (%)	85,56	89,58	82,68

Akumulatora izmantošana ar sliekšni 3 palielināja sākuma aizkavi. Pielāgotajam modelim ar akumulatoru mediānā sākuma aizkave bija 2,62 s. Tas ir sagaidāms, jo akumulators pirms stāvokļa maiņas pieprasa vairākas secīgas vai pietiekami stabilas prognozes. Līdz ar to tas samazina īslaicīgu trokšņainu pārslēgšanos, bet par šo stabilitāti tiek maksāts ar lēnāku vingrošanas sākuma noteikšanu. Šī sakarība redzama arī fragmentācijas piemērā 6.6. att., kur akumulators izlīdzina īslaicīgās stāvokļa maiņas, bet vingrošanas stāvoklis sākas vēlāk nekā modeļa neapstrādātajā signālā.

Sākuma aizkavēs tika novērotas arī negatīvas vērtības (6.7. att.). Tas nozīmē, ka sistēma vingrošanas stāvokli noteica pirms anotētā vingrinājuma sākuma. Šādas vērtības var rasties vairāku iemeslu dēļ: dalībnieks var ieņemt sākuma pozīciju pirms sākuma anotācijas, veikt sagatavošanās kustības vai izmēģinājuma atkārtojumu, kā arī anotācijas brīdis var nedaudz atšķirties no faktiskā kustības sākuma. Tāpēc negatīva aizkave ne vienmēr nozīmē modeļa kļūdu, bet var atspoguļot arī anotācijas un reālās kustības robežas nenoteiktību.




6.7. att. Vingrošanas sākuma noteikšanas aizkaves

Beigu aizkaves sadalījums parāda līdzīgu kompromisu (6.8. att.). Sākotnējā un pielāgotā modeļa beigu noteikšana bieži bija tuvu anotētajam vingrinājuma beigām, savukārt akumulatora izmantošana pārbīdīja beigu noteikšanu vēlāk. Tas nozīmē, ka pēc vingrinājuma

beigām sistēma ilgāk saglabā vingrošanas stāvokli. Adaptīvās mūzikas kontekstā tas var būt pieņemami, ja mūzikas pāreja uz mierīgāku stāvokli nav nepieciešama uzreiz.

Tika novērotas arī negatīvas beigu aizkaves, kad sistēma pārslēdzās uz nevingrošanas stāvokli pirms anotētā vingrinājuma beigām. Tas varētu notikt, ja vingrinājuma beigās kustība kļūst lēnāka, ja pēdējie atkārtojumi rada vājāku vai mazāk periodisku signālu, vai arī ja anotētā beigu robeža ietver svaru nolikšanu vai īsu pauzi pēc aktīvās kustības beigām.



6.8. att. Vingrošanas beigu noteikšanas aizkaves

Kopumā aizkaves rezultāti parāda, ka pielāgotais modelis spēj noteikt vingrošanas sākumu salīdzinoši ātri un samazina daļu garo aizkavju. Savukārt akumulators būtiski uzlabo signāla stabilitāti, bet palielina gan sākuma, gan beigu aizkavi. Tāpēc adaptīvās mūzikas sistēmā akumulatora sliekšnis jāizvēlas kā kompromiss starp stabilu mūzikas stāvokli un pietiekami ātru reakciju uz vingrinājuma sākumu un beigām.

6.5 Kļūdainās aktivizācijas nevingrojot

Papildus vingrošanas segmentu noteikšanai tika analizētas arī kļūdainās aktivizācijas atpūtas laikā. Kļūdaina aktivizācija šajā gadījumā nozīmē, ka sistēma ārpus anotēta vingrošanas segmenta pāriet stāvoklī “vingro”. Adaptīvās mūzikas kontekstā šādas aktivizācijas varētu radīt nevēlamas pārejas uz enerģiskāku mūziku atpūtas periodos.

Sākotnējais modelis atpūtas laikā aktivizējās bieži: vidēji 7,02 reizes vienā atpūtas segmentā jeb 2,21 reizes minūtē. Pēc modeļa pielāgošanas kļūdaino aktivizāciju skaits samazinājās līdz vidēji 5,00 aktivizācijām atpūtas segmentā jeb 1,71 aktivizācijām minūtē (6.4. tabula). Tas norāda, ka pielāgošana samazina daļu kļūdaino vingrošanas stāvokļa pāreju, tomēr atpūtas periodos signāls joprojām saglabājas trokšņains.

Vislielāko ietekmi uz kļūdaino aktivizāciju biežumu deva akumulatora izmantošana ar sliekšni 3. Šajā gadījumā vidējais aktivizāciju skaits atpūtas segmentā samazinājās līdz 1,61,

bet aktivizāciju skaits minūtē līdz 0,73. Tātad akumulators būtiski samazina īslaicīgas kļūdainas pārejas uz vingrošanas stāvokli.

Tomēr akumulatora izmantošanai ir arī trūkums: atlikušās kļūdainās aktivizācijas kļūst ilgākas. Sākotnējam un pielāgotajam modelim mediānais kļūdainās aktivizācijas ilgums bija 1,01 s, bet pielāgotajam modelim ar akumulatoru tas pieauga līdz 4,01 s. Līdzīgi vidējais aktivizācijas ilgums pieauga no 2,47 s pielāgotajam modelim līdz 5,93 s pielāgotajam modelim ar akumulatoru. Tas ir sagaidāms, jo akumulators samazina īsas stāvokļa svārstības, bet, kad kļūdaina aktivizācija tomēr notiek, sistēmai nepieciešams ilgāks laiks, lai atgrieztos nevingrošanas stāvoklī.

Adaptīvās mūzikas kontekstā šis rezultāts nav viennozīmīgs. Mazāks kļūdaino aktivizāciju skaits ir vēlams, jo tas samazina biežu mūzikas pārslēgšanos atpūtas laikā. Tomēr ilgākas kļūdainās aktivizācijas var nozīmēt, ka enerģiskā mūzika atsevišķos gadījumos turpinās ilgāk nekā nepieciešams. Tāpēc akumulators uzlabo signāla stabilitāti, bet arī šeit redzams kompromiss starp stabilu stāvokļa uzturēšanu un ātru kļūdainas aktivizācijas izbeigšanu.

6.4. tabula

Kļūdaino vingrošanas aktivizāciju rādītāji atpūtas laikā

Novērtējums	Sākotnējais	Pielāgotais	Pielāgotais ar sliekšni 3
Vidējais aktivizāciju skaits atpūtas segmentā	7,35	4,18	1,58
Mediānais aktivizāciju skaits atpūtas segmentā	5,00	3,00	1,00
Aktivizācijas minūtē	2,46	1,54	0,76
Vidējais aktivizāciju ilgums (s)	2,01	2,38	5,07
Mediānais aktivizācijas ilgums (s)	1,01	1,01	3,02

6.6 Kopsavilkums


Ievāktās treniņu sesijas parāda, ka sākotnējais modelis spēj noteikt daļu vingrošanas periodu, tomēr ar publiskajām RecoFit un MyoGym datu kopām vien nepietiek, lai iegūtu pietiekami stabilu un precīzu signālu šajā eksperimenta vidē. Sākotnējā modeļa rezultātos bija redzams zemāks vingrošanas pārklājums, lielāka segmentu fragmentācija un biežākas kļūdainas aktivizācijas atpūtas laikā.

Modeļa pielāgošana ar ievāktajām treniņu sesijām būtiski uzlaboja vingrošanas noteikšanu. Pielāgotais modelis labāk atpazīna vingrošanas periodus dažādās muskuļu grupās un vairākos gadījumos spēja noteikt arī vingrinājumus, kas nebija tieši iekļauti publiskajās

apmācības datu kopās. Tomēr pielāgošana pati par sevi negarantēja stabilu stāvokļa signālu: vingrošanas segmenti joprojām bieži tika sadalīti vairākos fragmentos.

Pēcāpstrāde ar akumulatoru būtiski samazināja segmentu fragmentāciju un kļūdaino aktivizāciju skaitu atpūtas laikā. Tas padara signālu piemērotāku adaptīvās mūzikas vadībai, jo samazinās biežu un īslaicīgu mūzikas pārslēgšanos risks. Vienlaikus akumulators palielināja sākuma un beigu aizkavi, tāpēc šī pieeja veido kompromisu starp signāla stabilitāti un reakcijas ātrumu.

6.9. att. un 6.6. att. ir redzama šī kompromisa praktiskā nozīme. Sākotnējais modelis rada trokšņainu signālu ar biežām īslaicīgām aktivizācijām un pārtraukumiem. Pielāgotais modelis labāk nosedz vingrošanas periodus, bet joprojām var būt fragmentēts. Savukārt pielāgotais modelis ar akumulatoru veido stabilākus vingrošanas stāvokļa posmus, taču tie sākas un beidzas ar lielāku aizkavi. Adaptīvās mūzikas kontekstā tas nozīmē, ka šāda sistēma varētu būt izmantojama vingrošanas un atpūtas stāvokļu noteikšanai, bet tās darbība ir atkarīga no izvēlētajā kompromisa starp ātru reakciju un stabilu mūzikas stāvokli.



6.9. att. Vienas sesijas pielāgošanas un akumulatora ar sliekšni 3 ietekme uz sākotnējā un pielāgotā modeļa vingrošanas stāvokļa prognozēm

7 DISKUSIJA

Šī darba rezultāti papildina RISE [1] darbā identificēto problēmu. RISE parāda, ka adaptīvu mūziku var izmantot trenāžieru zāles treniņā, taču vingrošanas un atpūtas periodi RISE sistēmā tiek iegūti no iepriekš definēta plāna vai manuālas ievades. Šajā darbā tika pārbaudīts, vai šādu vadības signālu var iegūt automātiski ar viedpulksteņa IMU datiem. Rezultāti rāda, ka tas ir iespējams, taču praktiskai izmantošanai īpaši svarīga ir ne tikai vingrošanas noteikšana, bet arī signāla stabilitāte un aizkave.

Atšķirībā no treniņa izsekošanas sistēmām, piemēram, RecoFit [3], MiLift [4] un uLift [5], adaptīvās mūzikas vadībai nav pietiekami pēc tam precīzi atrast vingrošanas segmentu. Mūzikas pāreja var notikt tikai tad, kad sistēma reāllaikā ir ieguvusi stāvokļa signālu. Tādēļ šajā darbā īpaši svarīgas ir aizkaves, fragmentācijas un kļūdaino aktivizāciju metrikas, nevis tikai logu klasifikācijas precizitāte.

Darbam ir vairāki ierobežojumi. Reāllaika eksperiments tika veikts ar desmit treniņu sesijām un tikai vienu viedpulksteņa modeli uz tikai labās rokas. Darbā netika veikts lietotāju pētījums ar reālu adaptīvās mūzikas sistēmu, tāpēc nav tieši novērtēts, kā lietotāji uztvertu aizkavi, kļūdainas aktivizācijas vai mūzikas pāreju biežumu. Turklāt šajā darbā tika izvērtēta viena praktiska pieeja vingrošanas noteikšanai - CNN modelis ar pēcapstrādi. Tādēļ rezultāti nav interpretējami kā pierādījums, ka šī ir optimālākā metode.

Turpmākajā darbā būtu nepieciešams izvērtēt alternatīvas vingrošanas noteikšanas metodes un pārbaudīt sistēmu plašākā reāllaika eksperimentā ar vairāk dalībniekiem un vingrinājumu izpildījuma variantiem. Nākamais solis būtu apvienot automātisko vingrošanas noteikšanu ar adaptīvās mūzikas prototipu un veikt lietotāju pētījumu, līdzīgi kā RISE, bet aizstājot manuāli ievadītu vingrošanas stāvokli ar automātiski noteiktu stāvokļa signālu.

8 SECINĀJUMI

Darbā tika pētīta vingrošanas un atpūtas periodu noteikšana trenāžieru zāles vidē, izmantojot viedpulksteņa inerces sensoru datus. Darba mērķis bija novērtēt, vai šādu signālu var izmantot treniņam adaptīvas mūzikas vadībai, kur vingrošanas laikā tiktu aktivizēts enerģiskāks mūzikas stāvoklis, bet atpūtas laikā mierīgāks.

Darba ietvaros tika apskatīti adaptīvās mūzikas un trenāžieru zāles aktivitāšu atpazīšanas risinājumi, izveidots CNN modelis binārai vingrošanas noteikšanai, apmācīts uz publiskajām RecoFit un MyoGym datu kopām un izvietots darbībai reāllaikā uz Samsung Galaxy Watch 8 viedpulksteņa, kur tas katru sekundi klasificēja pēdējo 2 sekunžu IMU sensoru datu logu. Praktiskā eksperimenta veikšanai tika izstrādātas divas Android lietotnes. Viedpulksteņa lietotne darbināja klasifikācijas modeli reāllaikā, ievāca inerces sensoru datus un saglabāja modeļa klasifikācijas rezultātus turpmākai analīzei. Telefona lietotne tika izmantota eksperimenta vadībai: tā sāka ierakstu gan telefonā, gan viedpulkstenī, kā arī ļāva anotēt vingrinājumu sākuma un beigu brīžus.

Ar izstrādātajām lietotnēm tika ievākta reālu treniņu datu kopa: 10 treniņu sesijas ar 10 dalībniekiem, kuru kopējais ilgums bija 13 stundas un 19 minūtes. Datu kopā tika anotēti 197 vingrinājumu piegājieni 41 unikāliem vingrinājumiem, aptverot 7 muskuļu grupas. Šī datu kopa ļāva novērtēt ne tikai logu klasifikācijas rezultātus, bet arī reāllaika pielietojumam svarīgas īpašības: vingrinājumu segmentu pārklājumu, noteikšanas aizkavi, fragmentāciju un kļūdainās aktivizācijas atpūtas laikā.

Rezultāti uz publiskajām datu kopām parādīja, ka CNN modelis spēj labi atšķirt vingrošanas un nevingrošanas logus. Tomēr reāllaika eksperimenta treniņu sesijās sākotnējais modelis nepietiekami labi vispārināja uz šo eksperimenta vidi. Pēc modeļa pielāgošanas ar ievāktajiem datiem vingrošanas noteikšanas rezultāti būtiski uzlabojās, īpaši vingrošanas pārklājums un F1 rādītājs.

Tika secināts, ka tikai logu klasifikācijas rezultāti nav pietiekami, lai novērtētu sistēmas piemērotību adaptīvai mūzikai. Praktiskam pielietojumam būtiska ir arī stāvokļa signāla stabilitāte, noteikšanas aizkave un kļūdainās aktivizācijas atpūtas laikā. Ar ievāktajiem datiem pielāgotais modelis labāk atpazīna vingrošanas periodus, bet signāls joprojām varēja būt fragmentēts. Pēc apstrāde ar akumulatoru būtiski samazināja fragmentāciju un kļūdaino aktivizāciju skaitu, tomēr palielināja sākuma un beigu aizkavi.

Kopumā darbs parāda, ka viedpulkstenī reāllaikā darbināts CNN modelis ir perspektīva pieeja reāllaika vingrošanas noteikšanai trenāžieru zālē. Šāda sistēma potenciāli var tikt izmantota adaptīvās mūzikas vadībai, tomēr praktiskā pielietojumā nepieciešams rūpīgi izvēlēties kompromisu starp ātru reakciju un stabilu stāvokļa signālu. Turpmākajā darbā būtu nepieciešams salīdzināt alternatīvas vingrošanas noteikšanas metodes un veikt lietotāju pētījumu ar reālu adaptīvās mūzikas prototipu.

PATEICĪBA

Darba autors izsaka pateicību visiem sportistiem, kuri piedalījās datu kopas izveidē:
Nilam Baumanim, Gunāram Ābeltiņam, Aleksejam Šepeļevam, Janai Kraulišai, Heinrikam
Lecim, Ričardam Ratke, Ričardam Bubišam, Ērikam Sobodam, Ralfam Grausam un Terēzei
Ozolniecei.

IZMANTOTĀ LITERATŪRA UN AVOTI


- [1] Wang A., Donahue C. un Jain D. *RISE: Adaptive music playback for Realtime Intensity Synchronization with Exercise* [tiešsaiste]. arXiv. 21. septembris 2025 [skatīts 16.12.2025.]. Pieejams: doi:10.48550/arXiv.2509.17112. arXiv:2509.17112 [cs]
- [2] Brennan T.R., Weakley J., Johnston R.D. un Creaby M.W. Exercise Classification in Resistance Training: A Systematic Review of Technological Approaches. *Sports Medicine (Auckland, N.Z.)* [tiešsaiste]. 2025, **55**(10), 2529–2565. ISSN 1179-2035. Pieejams: doi:10.1007/s40279-025-02281-8
- [3] Morris D., Saponas T.S., Guillory A. un Kelner I. RecoFit: using a wearable sensor to find, recognize, and count repetitive exercises. No: *CHI '14: CHI Conference on Human Factors in Computing Systems: Proceedings of the SIGCHI Conference on Human Factors in Computing Systems* [tiešsaiste]. Toronto Ontario Canada: ACM, 2014, 3225–3234 lpp. [skatīts 07.12.2025.]. ISBN 978-1-4503-2473-1. Pieejams: doi:10.1145/2556288.2557116
- [4] Shen C., Ho B.-J. un Srivastava M. MiLift: Efficient Smartwatch-Based Workout Tracking Using Automatic Segmentation. *IEEE Transactions on Mobile Computing* [tiešsaiste]. 2018, **17**(7), 1609–1622. ISSN 1558-0660. Pieejams: doi:10.1109/TMC.2017.2775641
- [5] Lim J., Oh Y. un Choi Y. uLift: Adaptive Workout Tracker Using a Single Wrist-Worn Accelerometer. *IEEE Access* [tiešsaiste]. 2024, **12**, 21710–21722. ISSN 2169-3536. Pieejams: doi:10.1109/ACCESS.2024.3363437
- [6] Mekruksavanich S., Tancharoen D. un Jitpattanakul A. Gym Exercise Recognition Using Deep Convolutional and LSTM Neural Network Based on IMU Sensor Data. *2024 International Technical Conference on Circuits/Systems, Computers, and Communications (ITC-CSCC)* [tiešsaiste]. 2024, 1–5. Pieejams: doi:10.1109/ITC-CSCC62988.2024.10628426
- [7] Koskimäki H., Siirtola P. un Rönning J. MyoGym: introducing an open gym data set for activity recognition collected using myo armband. [tiešsaiste]. 2017, 537–546 lpp. Pieejams: doi:10.1145/3123024.3124400
- [8] Redhead T. *Interactive Technologies and Music Making: Transmutable Music* [tiešsaiste]. London: Focal Press, 2024. ISBN 978-1-003-27355-4. Pieejams: doi:10.4324/9781003273554
- [9] FRITSCH, Melanie un Tim SUMMERS, red. *The Cambridge Companion to Video Game Music* [tiešsaiste]. Cambridge: Cambridge University Press, 2021 [skatīts 02.01.2026.]. Cambridge Companions to Music. ISBN 978-1-108-47302-6. Pieejams: doi:10.1017/9781108670289
- [10] Danso A., Kekäläinen T., Koehler F., Knittle K., Nijhuis P., Burunat I., Neto P., Mavrolampados A., Randall W.M., Hansen N.C., Ansani A., Rantalainen T., Alluri V., Hartmann M., Schaefer R.S., Ihalainen J.K., Rousi R., Agres K.R., MacRitchie J., Toiviainen P., Saarikallio S., Chastin S. un Luck G. Personalized Interactive Music Systems for Physical Activity and Exercise: Exploratory Systematic Review and Meta-Analysis. *JMIR Human Factors* [tiešsaiste]. 2025, **12**(1), e70372. Pieejams: doi:10.2196/70372

- [11] Buhmann J., Moens B., Van Dyck E., Dotov D. un Leman M. Optimizing beat synchronized running to music. *PLOS ONE* [tiešsaiste]. 2018, **13**(12), e0208702. ISSN 1932-6203. Pieejams: doi:10.1371/journal.pone.0208702
- [12] Chen Y., Chen C.-C., Tang L.-C. un Chieng W.-H. Enhancing Running Exercise With IoT, Blockchain, and Heart Rate Adaptive Running Music. *IEEE Access* [tiešsaiste]. 2024, **12**, 14168–14181. ISSN 2169-3536. Pieejams: doi:10.1109/ACCESS.2024.3355792
- [13] Moens B., Muller C., Noorden L. van, Franěk M., Celie B., Boone J., Bourgois J. un Leman M. Encouraging Spontaneous Synchronisation with D-Jogger, an Adaptive Music Player That Aligns Movement and Music. *PLOS ONE* [tiešsaiste]. 2014, **9**(12), e114234. ISSN 1932-6203. Pieejams: doi:10.1371/journal.pone.0114234
- [14] Rehfeld K., Fritz T.H., Prinz A., Schneider L., Villringer A. un Witte K. Musical feedback system Jymmin® leads to enhanced physical endurance in the elderly—A feasibility study. *Frontiers in Sports and Active Living* [tiešsaiste]. 2022, **4** [skatīts 03.01.2026.]. ISSN 2624-9367. Pieejams: doi:10.3389/fspor.2022.915926
- [15] Carôt A., Fritz T.H. un Englert K. Towards a System Supporting Music Feedback Exercise in Physical Tele-Rehabilitation. No: 2023 4th International Symposium on the Internet of Sounds: 2023 4th International Symposium on the Internet of Sounds [tiešsaiste]. 2023, 1–7 lpp. [skatīts 03.01.2026.]. Pieejams: doi:10.1109/IEEECONF59510.2023.10335285
- [16] Mekruksavanich S. un Jitpattanakul A. A Residual Deep Learning Method for Accurate and Efficient Recognition of Gym Exercise Activities Using Electromyography and IMU Sensors. *Applied System Innovation* [tiešsaiste]. 2024, **7**(4), 59. ISSN 2571-5577. Pieejams: doi:10.3390/asi7040059
- [17] Wang Z., Yan W. un Oates T. *Time Series Classification from Scratch with Deep Neural Networks: A Strong Baseline* [tiešsaiste]. arXiv. 14. decembris 2016 [skatīts 10.01.2026.]. Pieejams: doi:10.48550/arXiv.1611.06455. arXiv:1611.06455 [cs]
- [18] Birznieks M. Trenažieru zāles vingrošanas noteikšana treniņam adaptīvai mūzikai: darba pirmkoda repozitorijs. *GitHub* [tiešsaiste]. [skatīts 25.05.2026.]. Pieejams: <https://github.com/Markuss-B/GAR>
- [19] LiteRT: High-Performance On-Device Machine Learning Framework | Google AI Edge. *Google AI for Developers* [tiešsaiste]. [skatīts 22.05.2026.]. Pieejams: <https://ai.google.dev/edge/litert>
- [20] *Use wake locks | Background work | Android Developers* [tiešsaiste]. [skatīts 22.05.2026.]. Pieejams: <https://developer.android.com/develop/background-work/background-tasks/awake/wakelock>

PIELIKUMS

1. pielikums

Sākotnējā un pielāgotā modeļa vingrinājumu segmentu pārklājums
pa vingrinājumiem un muskuļu grupām



Apliecinājums

Es apliecinu, ka bakalaura darbs „Trenažieru zāles vingrošanas noteikšana treniņam adaptīvai mūzikai” ir izstrādāts patstāvīgi Latvijas Universitātē Eksakto zinātņu un tehnoloģiju fakultātes Datorikas nodaļā, izmantojot tikai darbā norādītos informācijas avotus, un tas ir mans oriģināldarbs.

Iesniedzot šo darbu Latvijas Universitātes informācijas sistēmās, autentificējoties ar saviem piekļuves datiem, apliecinu savu identitāti un to, ka iesniegtā darba elektroniskā versija ir galīgā un autentiskā darba versija.

Markuss Birznieks